

Anforderungskatalog

Requirements Catalog

An LLM-Driven ETL Platform for Climate-Health Data Integration

Bachelor-Arbeit / Bachelor Thesis

Universität Bremen – Fachbereich Informatik

Autor / Author: **Sergi Koniashvili**

Stand / Date: October 7, 2026

Dieses Dokument beschreibt den umfassenden funktionalen und nicht-funktionalen Anforderungskatalog für die entwickelte Software-Plattform, einschließlich aller Erweiterungen (Copilot, Literatur-RAG, Demografie, statistische Lags und Downscaling) sowie den aktuellen Umsetzungsstand.

Contents

Teil I – Deutsch	2
1 Einleitung und Zielsetzung	2
2 Funktionale Anforderungen (FR)	2
3 Nicht-funktionale Anforderungen (NFR)	4
4 Architekturüberblick	5
5 Validierung	5
 Part II – English	 6
6 Introduction and Objectives	6
7 Functional Requirements (FR)	6
8 Non-Functional Requirements (NFR)	8
9 Architecture Overview	9
10 Validation	9

Teil I – Deutsch

1 Einleitung und Zielsetzung

Viele Infektionskrankheiten sind hochgradig klimasensitiv: Ihre biologischen Vektoren (z. B. *Aedes aegypti*- und *Anopheles*-Mücken) reagieren empfindlich auf Temperatur, Niederschlag und Luftfeuchtigkeit. Hochaufgelöste Klimadaten dienen daher als essenzieller Frühindikator für Ausbruchsrisiken.

Die im Rahmen dieser Bachelorarbeit entwickelte Plattform ermöglicht es Forschenden, Behörden und Interessierten ohne Programmier- oder Klimawissenschaftskenntnisse, per natürlichsprachlicher Eingabe oder interaktiver Steuerung analysebereite, klimabezogene Gesundheits- und Demografiedatensätze zu erstellen. Ein Large Language Model (LLM) übersetzt Anfragen in strukturierte Integrationspläne, ruft Daten aus offiziellen wissenschaftlichen Archiven ab, harmonisiert unterschiedliche zeitliche und räumliche Auflösungen und liefert eine fundierte, laiengerechte Erklärung sowie statistische Korrelationsanalysen.

Validierungsszenario: Denguefieber in Thailand, mit voller Generalisierbarkeit auf weitere vektorübertragene Infektionskrankheiten (Malaria, Cholera, West-Nil-Virus u. a.) und globale Regionen.

2 Funktionale Anforderungen (FR)

ID	Beschreibung	Herkunft	Status
FR-01	Das System muss eine natürlichsprachliche Anfrage (Krankheit, Region, Klimavariablen, Zeitspanne) entgegennehmen und per LLM in einen strukturierten Integrationsplan übersetzen.	Projektkonzept	Umgesetzt
FR-02	Die Welt muss in auswählbare Regionen unterteilt sein; die Nutzerin/der Nutzer muss Ergebnisse regionsspezifisch abrufen können (39 Länder hinterlegt).	Auflage Betreuer	Umgesetzt
FR-03	Das System muss jeden Verarbeitungsschritt (Abruf, Validierung, Harmonisierung, Verknüpfung) sichtbar protokollieren.	Auflage Betreuer	Umgesetzt
FR-04	Klimadaten müssen ausschließlich aus wissenschaftlichen/offiziellen Quellen stammen (ERA5, NASA POWER, TMD).	Auflage Betreuer	Umgesetzt
FR-05	Die Nutzerin/der Nutzer muss zwischen mehreren wissenschaftlichen Datenquellen wählen können.	Auflage Betreuer	Umgesetzt
FR-06	Die Nutzerin/der Nutzer muss eine eigene Datenquelle per URL angeben können (Fallzahlen, Wetter, Demografie).	Auflage Betreuer	Umgesetzt
FR-07	Die Nutzerin/der Nutzer muss eine eigene Datenquelle als CSV-Datei hochladen können (Fallzahlen, Wetter, Demografie).	Auflage Betreuer	Umgesetzt

ID	Beschreibung	Herkunft	Status
FR-08	Empfangene und erzeugte Datensätze müssen als CSV und JSON heruntergeladen werden können.	Auflage Betreuer	Umgesetzt
FR-09	Das System muss jeden Schritt und die epidemiologische Beziehung in verständlicher Sprache erklären.	Projektkonzept	Umgesetzt (LLM-generiert)
FR-10	Das System muss Datenabruf und Validierung unter Beachtung von API-Ratenlimits durchführen, ohne die UI zu blockieren.	Nutzeranforderung	Umgesetzt
FR-11	Das System muss bereits verarbeitete Daten cachen und mit Zeitstempel der letzten Überprüfung (<code>last_verified</code>) anzeigen.	Nutzeranforderung	Umgesetzt
FR-12	Das System muss modular auf weitere Krankheiten und Regionen erweiterbar sein, ohne die Kernarchitektur zu ändern.	Projektkonzept	Umgesetzt
FR-13	Das System muss einen interaktiven Copilot-Chatassistenten bieten, der Fachfragen beantwortet, Formularparameter vorschlägt und Suchläufe direkt auslöst.	Erweiterung / UX	Umgesetzt
FR-14	Das System muss eine wissenschaftliche Literatur-Wissensbasis (WHO, Lancet, IPCC, Mordecai et al.) bereitstellen, Vergleiche erläutern und RAG-In-Context-Grounding ermöglichen.	Fachliche Anforderung	Umgesetzt
FR-15	Das System muss Metadaten aus wissenschaftlichen PDF-Dateien oder Web-Links automatisiert per KI extrahieren und strukturieren.	Erweiterung / KI	Umgesetzt
FR-16	Das System muss eine Live-Suche für externe Fallzahldatenquellen (WHO GHO Indikatoren und HDX-Datensätze) bereitstellen.	Erweiterung / Daten	Umgesetzt
FR-17	Das System muss offizielle Demografiedaten (World Bank Indikatoren, UN WPP, Upload) durchsuchbar anbinden und Inzidenzraten pro 100.000 Einwohner berechnen.	Fachliche Anforderung	Umgesetzt
FR-18	Das System muss für benutzerdefinierte Uploads einen lückenlosen Transformations-Audit-Trail führen und verständlich erläutern.	Qualitätsanforderung	Umgesetzt
FR-19	Das System muss zeitverzögerte Kreuzkorrelationen (Lags 0–3) mit Pearson- r und p -Wert-Signifikanz berechnen.	Analytische Anforderung	Umgesetzt

ID	Beschreibung	Herkunft	Status
FR-20	Das System muss bei täglicher Auflösung eine massenerhaltende glatte zeitliche Interpolation durchführen und Auflösungshinweise geben.	Methodische Anforderung	Umgesetzt
FR-21	Das System muss eine vollständig dreisprachige Benutzeroberfläche (Deutsch, Englisch, Georgisch) mit Live-Umschaltung bieten.	Nutzeranforderung	Umgesetzt
FR-22	Das System muss einen druckreifen wissenschaftlichen PDF-Analysebericht mit Diagrammen, Tabellen und Zitationen generieren können.	Nutzeranforderung	Umgesetzt
FR-23	Das System muss eine interaktive Weltkarte zur intuitiven visuellen Länderauswahl bereitstellen.	Usability-Anforderung	Umgesetzt

3 Nicht-funktionale Anforderungen (NFR)

ID	Beschreibung	Herkunft	Status
NFR-01	Ratenlimit-Schutz: Das System darf das Kontingent der LLM-API nicht überschreiten (Sliding-Window-Begrenzung).	Betriebsanforderung	Umgesetzt
NFR-02	Wissenschaftliche Zitierfähigkeit: Jede Antwort muss verwendete Primärquellen (Klima, Fälle, Demografie, Literatur) exakt zitieren.	Wissenschaftspraxis	Umgesetzt
NFR-03	Portabilität: Die gesamte Plattform (FastAPI-Backend + Flutter-Web-Frontend) muss als einzelner Docker-Container lauffähig sein.	DevOps / Betrieb	Umgesetzt
NFR-04	Datensicherheit: API-Schlüssel und Zugangsdaten dürfen niemals im Quellcode oder im Client-Bundle exponiert werden.	Sicherheitsanforderung	Umgesetzt (.env, .gitignore)
NFR-05	Verständlichkeit: Erklärungen müssen für Personen ohne Vorkenntnisse in Klimamodellierung oder Informatik intuitiv begreifbar sein.	Projektkonzept	Umgesetzt
NFR-06	Wartbarkeit: Strikte Trennung von Datenextraktion, Harmonisierung, statistischer Analyse und Präsentation in modularen Services.	Software-Engineering	Umgesetzt

ID	Beschreibung	Herkunft	Status
NFR-07	RAG-Integrität: Das System nutzt In-Context Grounding statt Modell-Feintuning; neuronale Gewichte bleiben unverändert.	Wissenschaftsethik	Umgesetzt
NFR-08	Mathematische Massenerhaltung: Die zeitliche Interpolation auf Tagesebene erhält exakt die Gesamtsumme der gemeldeten Primärfälle.	Datenintegrität	Umgesetzt
NFR-09	Sprachkonsistenz: Vermeidung von Sprachmischungen; alle Interface-Texte liegen konsistent in de, en und ka vor.	Usability / i18n	Umgesetzt

4 Architekturüberblick

Die Plattform basiert auf einer Drei-Schichten-Architektur:

- (1) **Frontend (Flutter Web):** Reaktive Einzelseiten-Applikation mit mehrsprachiger Benutzeroberfläche, Copilot-Drawer, Literatur-Korpus-Verwaltung, Daten-Audit-Anzeige, interaktiver Weltkarte und PDF-Export.
- (2) **Backend (Python, FastAPI):** Modulare Service-Architektur für Pipeline-Orchestrierung (etl), Klimadatenzugriff (climate, tmd), Surveillance-Erfassung (case_data, who_gho, hdx), Demografie (population), Korrelationsstatistik (statistics), automatisierte Literatur-Extraktion (literature_extractor) sowie LLM-Copilot-Dienste (llm, chat).
- (3) **Wissenschaftliche Primärquellen:** Reanalyse-APIs (Open-Meteo ERA5, NASA POWER, TMD), globale Gesundheitsdaten (OpenDengue, WHO GH0, HDX), Demografie (Weltbank WDI, UN WPP) und Google Gemini LLM.

5 Validierung

Das Pipeline-Design wurde primär anhand von Denguefieber in Thailand (1990–2023) validiert. Es ist vollständig generalisierbar auf alle 39 hinterlegten Länder sowie frei konfigurierbar für beliebige nutzerdefinierte Datensätze.

Part II – English

6 Introduction and Objectives

Many infectious diseases are strongly climate-sensitive: their biological vectors (e.g., *Aedes aegypti* and *Anopheles* mosquitoes) exhibit acute sensitivity to ambient temperature, rainfall, and relative humidity. High-resolution meteorological data therefore serves as a vital early indicator of disease transmission suitability and outbreak hazards.

The software platform developed for this bachelor thesis enables researchers, public health officials, and decision-makers without programming or meteorological backgrounds to obtain analysis-ready, climate-harmonized epidemiological datasets. Through natural language input or direct form selection, a Large Language Model (LLM) translates user intent into an executable ETL pipeline plan, queries verified international repositories, harmonizes conflicting temporal and spatial resolutions, computes demographic incidence rates, and performs statistical lag cross-correlations with plain-language explanations.

Validation Scenario: Dengue fever in Thailand, with architectural extensibility to further vector-borne diseases (malaria, cholera, West Nile virus) and global regions.

7 Functional Requirements (FR)

ID	Description	Origin	Status
FR-01	The system must accept natural language queries (disease, region, climate variables, dates) and translate them via LLM into a structured integration plan.	Project concept	Implemented
FR-02	The world must be partitioned into selectable regions; users must be able to retrieve region-specific datasets (39 countries registered).	Supervisor requirement	Implemented
FR-03	The system must visibly log every pipeline execution step (retrieval, validation, harmonization, joining, statistical evaluation).	Supervisor requirement	Implemented
FR-04	Meteorological series must originate strictly from authoritative scientific sources (ERA5, NASA POWER, TMD).	Supervisor requirement	Implemented
FR-05	Users must be able to choose between multiple verified scientific data sources.	Supervisor requirement	Implemented
FR-06	Users must be able to supply custom data sources via web URL (cases, weather, demographics).	Supervisor requirement	Implemented
FR-07	Users must be able to upload custom datasets as CSV files (cases, weather, demographics).	Supervisor requirement	Implemented
FR-08	Harmonized datasets must be downloadable locally in standard CSV and JSON formats.	Supervisor requirement	Implemented

ID	Description	Origin	Status
FR-09	The system must explain pipeline transformations and climate-health associations in clear, plain language.	Project concept	Implemented (LLM-generated)
FR-10	The system must respect upstream API rate limits asynchronously without blocking user interactions.	User requirement	Implemented
FR-11	The system must cache processed datasets and surface a verification freshness timestamp (<code>last_verified</code>).	User requirement	Implemented
FR-12	The system must be modularly extensible to additional diseases and regions without architectural refactoring.	Project concept	Implemented
FR-13	The system must provide an interactive Copilot chat assistant capable of domain dialogue, form prefill, and one-click execution.	UX requirement	Implemented
FR-14	The system must incorporate a verified literature knowledge base (WHO, Lancet, IPCC, Mordecai et al.) with RAG in-context grounding and comparison.	Domain requirement	Implemented
FR-15	The system must automatically extract and structure bibliographic metadata from uploaded PDFs or article URLs using AI.	AI requirement	Implemented
FR-16	The system must support real-time online discovery of official surveillance sources (live query of WHO GHO indicators and HDX datasets).	Data requirement	Implemented
FR-17	The system must integrate demographic indicators (World Bank Open Data, UN WPP, custom upload) and compute disease incidence per 100,000 population.	Domain requirement	Implemented
FR-18	The system must maintain an end-to-end Data Transformation Audit trail for custom uploads with natural-language explanation.	Audit requirement	Implemented
FR-19	The system must calculate time-lagged cross-correlations (Lags 0–3) with Pearson- r and p -value statistical significance.	Analytical requirement	Implemented
FR-20	The system must apply mass-preserving smooth temporal downscaling for daily surveillance resolution with user guidance.	Methodological requirement	Implemented
FR-21	The system must offer a fully trilingual user interface (English, German, Georgian) with instant runtime language switching.	User requirement	Implemented

ID	Description	Origin	Status
FR-22	The system must generate downloadable, publication-ready scientific PDF report digests with charts, tables, and citations.	User requirement	Implemented
FR-23	The system must feature an interactive world map for visual region and coordinate selection.	Usability requirement	Implemented

8 Non-Functional Requirements (NFR)

ID	Description	Origin	Status
NFR-01	Rate Limit Protection: The system must enforce sliding-window quotas to prevent exceeding upstream LLM API limits (15 req/min).	Operational requirement	Implemented
NFR-02	Scientific Traceability: Every system response must provide rigorous academic citations for all primary sources used.	Academic standards	Implemented
NFR-03	Portability: The complete software suite (FastAPI backend + Flutter Web) must be deployable as a single unified Docker container.	DevOps / Portability	Implemented
NFR-04	Security: Credentials and private API keys must never be committed to source control or exposed to client-side bundles.	Security standards	Implemented (.env, .gitignore)
NFR-05	Comprehensibility: Narratives and explanations must be interpretable by stakeholders without formal training in epidemiology or meteorology.	User-centric design	Implemented
NFR-06	Maintainability: Clean separation of configuration, data harvesting, orchestration, analysis, and presentation into decoupled modules.	Software engineering	Implemented
NFR-07	Grounding Integrity: RAG in-context grounding must be strictly maintained; model weights remain frozen, preventing hallucinated citations.	AI ethics	Implemented
NFR-08	Mathematical Conservation: Daily down-scaling must strictly conserve the integral case mass of the underlying official surveillance reports.	Data integrity	Implemented
NFR-09	Linguistic Consistency: Full parity across German, English, and Georgian without mixed-language artifacts.	i18n standards	Implemented

9 Architecture Overview

The platform follows a decoupled three-tier architecture:

- (1) **Presentation Tier (Flutter Web):** Reactive single-page web client supporting trilingual localization, Copilot drawer, literature corpus browser, transformation audit view, interactive world map, and PDF export.
- (2) **Service & Orchestration Tier (Python, FastAPI):** Modulated services for pipeline execution (`etl`), meteorological querying (`climate`, `tmd`), disease surveillance (`case_data`, `who_gho`, `hdx`), demographics (`population`), lag statistics (`statistics`), literature parsing (`literature_extractor`), and LLM copilot services (`llm`, `chat`).
- (3) **Authoritative Upstream Tier:** Climate reanalysis archives (Open-Meteo ERA5, NASA POWER, TMD), surveillance repositories (OpenDengue, WHO GH0, HDX), demographic databases (World Bank WDI, UN WPP), and Google Gemini LLM.

10 Validation

Pipeline efficacy is empirically demonstrated using historical dengue surveillance in Thailand (1990–2023). Architectural generality ensures immediate applicability across all 39 registered global jurisdictions and custom user-provided datasets.