

Anforderungskatalog

Requirements Catalog

An LLM-Driven ETL Platform for Climate-Health Data Integration

Bachelor-Arbeit / Bachelor Thesis

Universität Bremen – Fachbereich Informatik

Autor / Author: **Sergi Koniashvili**

Stand / Date: August 6, 2026

Dieses Dokument beschreibt den funktionalen und nicht-funktionalen Anforderungskatalog für die im Rahmen dieser Bachelorarbeit entwickelte Software-Plattform, sowie den aktuellen Umsetzungsstand.

Contents

Teil I – Deutsch	2
1 Einleitung	2
2 Funktionale Anforderungen (FR)	2
3 Nicht-funktionale Anforderungen (NFR)	3
4 Architekturüberblick	4
5 Validierung	4
 Part II – English	 5
6 Introduction	5
7 Functional Requirements (FR)	5
8 Non-Functional Requirements (NFR)	6
9 Architecture Overview	6
10 Validation	7

Teil I – Deutsch

1 Einleitung

Viele Krankheiten sind klimasensitiv: Ihre Überträger (z. B. Mücken) reagieren auf Temperatur, Niederschlag und Luftfeuchtigkeit, wodurch Klimadaten als Frühindikator für Ausbruchsriskien dienen können. Die im Rahmen dieser Bachelorarbeit entwickelte Plattform ermöglicht es einer Nutzerin bzw. einem Nutzer ohne Programmier- oder Klimawissenschaftskenntnisse, per natürlchsprachlicher Anfrage analysebereite, klimabezogene Gesundheitsdaten zu erhalten. Ein Large Language Model (LLM) übersetzt die Anfrage in einen ausführbaren Integrationsplan, der klimatische, epidemiologische und demografische Daten abrufen, bereinigt und zeitlich/räumlich harmonisiert – als Grundlage für nachgelagerte Krankheitsmodelle, nicht als Vorhersage selbst.

Validierungsszenario: Denguefieber in Thailand, mit Erweiterbarkeit auf weitere vektorübertragene Krankheiten (Malaria, Cholera, Lyme-Borreliose u. a.) und Regionen.

2 Funktionale Anforderungen (FR)

ID	Beschreibung	Herkunft	Status
FR-01	Das System muss eine natürlchsprachliche Anfrage (Krankheit, Region, Klimavariablen, Emissionsszenario) entgegennehmen und in einen strukturierten Integrationsplan übersetzen.	Projektkonzept	Umgesetzt
FR-02	Die Welt muss in auswählbare Regionen unterteilt sein; die Nutzerin/der Nutzer muss Ergebnisse regionsspezifisch abrufen können.	Auflage Betreuer	Umgesetzt (39 Länder mit realen Falldaten)
FR-03	Das System muss jeden Verarbeitungsschritt (Abruf, Validierung, Aggregation, Verknüpfung) sichtbar protokollieren, damit die Nutzerin/der Nutzer die korrekte Ausführung ihres Auftrags nachvollziehen kann.	Auflage Betreuer	Umgesetzt
FR-04	Klimadaten müssen ausschließlich aus wissenschaftlichen/offiziellen Quellen stammen (z. B. Reanalyse-Archive, begutachtete Surveillance-Datensätze).	Auflage Betreuer	Umgesetzt
FR-05	Die Nutzerin/der Nutzer muss zwischen mehreren wissenschaftlichen Datenquellen wählen können.	Auflage Betreuer	Umgesetzt (2 Klimaquellen, 1 Fallzahlen-Archiv)
FR-06	Die Nutzerin/der Nutzer muss eine eigene Datenquelle per URL angeben können.	Auflage Betreuer	Umgesetzt
FR-07	Die Nutzerin/der Nutzer muss eine eigene Datenquelle als Datei hochladen können.	Auflage Betreuer	Umgesetzt (CSV)

ID	Beschreibung	Herkunft	Status
FR-08	Empfangene/erzeugte Datensätze müssen gespeichert und auf den lokalen Rechner der Nutzerin/des Nutzers heruntergeladen werden können.	Auflage Betreuer	Umgesetzt (CSV, JSON)
FR-09	Das System muss jeden Schritt (z. B. Reanalyse vs. Modellprojektion, Bias-Korrektur) in einfacher Sprache erklären.	Projektkonzept	Umgesetzt (LLM-generiert)
FR-10	Das System muss Datenabruf und -validierung unter Beachtung von API-Ratenlimits durchführen, ohne die Nutzerin/den Nutzer zu blockieren.	Nutzeranforderung	Teilweise umgesetzt (serverseitiges Rate-Limiting; echte Hintergrund-Job-Warteschlange geplant)
FR-11	Das System soll bereits verarbeitete (gecachte) Daten anzeigen können, inkl. Zeitstempel der letzten Überprüfung.	Nutzeranforderung	Umgesetzt (In-Memory-Cache, 15 Min. TTL, last_verified-Feld)
FR-12	Das System muss auf weitere Krankheiten/Regionen erweiterbar sein, ohne die Kernarchitektur zu ändern.	Projektkonzept	Architektonisch vorbereitet (siehe Abschnitt 4)

3 Nicht-funktionale Anforderungen (NFR)

ID	Beschreibung	Herkunft	Status
NFR-01	Das System darf das Ratenlimit der verwendeten LLM-API nicht überschreiten (aktuell: 15 Anfragen/Minute).	Nutzeranforderung	Umgesetzt (Sliding-Window-Limiter)
NFR-02	Nachvollziehbarkeit: Jede Antwort muss die verwendeten Quellen wissenschaftlich zitieren.	Projektkonzept	Umgesetzt
NFR-03	Portabilität: Die Plattform muss als einzelner Container deploybar sein.	Betrieblichkeit	Umgesetzt (Docker, Multi-Stage-Build)
NFR-04	Vertraulichkeit: API-Schlüssel dürfen nicht im Quellcode oder Repository landen.	Sicherheitsanforderung	Umgesetzt (.env, .gitignore)

ID	Beschreibung	Herkunft	Status
NFR-05	Verständlichkeit: Erklärungen müssen für Personen ohne Programmier-/Klimawissenschaftshintergrund verständlich sein.	Projektkonzept	Umgesetzt
NFR-06	Wartbarkeit: Trennung von Konfiguration, Datenzugriff, Orchestrierung und Präsentation in klar abgegrenzten Modulen.	Software-Engineering-Praxis	Umgesetzt

4 Architekturüberblick

Die Plattform folgt einer Drei-Schichten-Architektur:

- (1) **Frontend (Flutter, Web – perspektivisch auch Mobile/Desktop):** Formular zur Anfrageerstellung, Ergebnisdarstellung (Schritte, Erklärung, Diagramm, Tabelle, Download).
- (2) **Backend (Python, FastAPI):** Validierung, Orchestrierung des ETL-Ablaufs, Cache- und Rate-Limit-Verwaltung, Anbindung an externe Datenquellen und das LLM.
- (3) **Externe Quellen:** Klima-Reanalyse-APIs (Open-Meteo/ERA5, NASA POWER), epidemiologisches Archiv (OpenDengue), nutzerdefinierte Quellen (URL/Upload), Gemini-LLM für die Klartext-Erklärung.

5 Validierung

Das Pipeline-Design wird anhand von Denguefieber in Thailand validiert und ist so allgemein gehalten, dass es ohne Architekturänderung auf weitere vektorübertragene Krankheiten und auf alle 39 aktuell hinterlegten Länder mit ausreichender epidemiologischer Datenabdeckung anwendbar ist.

Part II – English

6 Introduction

Many diseases are climate-sensitive: their vectors (e.g. mosquitoes) respond to temperature, rainfall, and humidity, making climate data a useful early indicator of outbreak risk. The platform developed for this bachelor thesis lets a user without programming or climate-science expertise obtain analysis-ready, climate-linked health data through a natural-language request. A large language model (LLM) translates the request into an executable integration plan that retrieves, cleans, and temporally/spatially harmonizes climate, epidemiological, and demographic data – as input for downstream disease models, not as a prediction in itself.

Validation scenario: dengue in Thailand, extensible to other vector-borne diseases (malaria, cholera, Lyme disease, etc.) and regions.

7 Functional Requirements (FR)

ID	Description	Origin	Status
FR-01	The system must accept a natural-language request (disease, region, climate variables, emission scenario) and translate it into a structured integration plan.	Project concept	Implemented
FR-02	The world must be divided into selectable regions; the user must be able to retrieve results per region.	Supervisor requirement	Implemented (39 countries with real case data)
FR-03	The system must visibly log every processing step (retrieval, validation, aggregation, joining) so the user can verify their request was executed correctly.	Supervisor requirement	Implemented
FR-04	Climate data must come exclusively from scientific/official sources (e.g. reanalysis archives, peer-reviewed surveillance datasets).	Supervisor requirement	Implemented
FR-05	The user must be able to choose between multiple scientific data sources.	Supervisor requirement	Implemented (2 climate sources, 1 case-count archive)
FR-06	The user must be able to point the system at a custom data source via URL.	Supervisor requirement	Implemented
FR-07	The user must be able to upload a custom data source as a file.	Supervisor requirement	Implemented (CSV)
FR-08	Received/generated datasets must be storable and downloadable to the user's local machine.	Supervisor requirement	Implemented (CSV, JSON)
FR-09	The system must explain every step (e.g. reanalysis vs. model projection, bias correction) in plain language.	Project concept	Implemented (LLM-generated)

ID	Description	Origin	Status
FR-10	The system must perform data retrieval and validation while respecting API rate limits, without blocking the user.	User requirement	Partially implemented (server-side rate limiting in place; a true background job queue is planned)
FR-11	The system should be able to show already-processed (cached) data, including a last-verified timestamp.	User requirement	Implemented (in-memory cache, 15-min TTL, <code>last_verified</code> field)
FR-12	The system must be extensible to further diseases/regions without changing the core architecture.	Project concept	Architecturally prepared (see Section 4)

8 Non-Functional Requirements (NFR)

ID	Description	Origin	Status
NFR-01	The system must not exceed the rate limit of the LLM API in use (currently: 15 requests/minute).	User requirement	Implemented (sliding-window limiter)
NFR-02	Traceability: every response must scientifically cite the sources it used.	Project concept	Implemented
NFR-03	Portability: the platform must be deployable as a single container.	Operability	Implemented (Docker, multi-stage build)
NFR-04	Confidentiality: API keys must never end up in source code or the repository.	Security requirement	Implemented (<code>.env</code> , <code>.gitignore</code>)
NFR-05	Comprehensibility: explanations must be understandable to people without a programming/climate-science background.	Project concept	Implemented
NFR-06	Maintainability: configuration, data access, orchestration, and presentation are separated into clearly scoped modules.	Software engineering practice	Implemented

9 Architecture Overview

The platform follows a three-tier architecture:

- (1) **Frontend (Flutter, Web – Mobile/Desktop planned):** request-building form, results presentation (steps, explanation, chart, table, download).

- (2) **Backend (Python, FastAPI):** validation, ETL orchestration, cache and rate-limit management, integration with external data sources and the LLM.
- (3) **External sources:** climate reanalysis APIs (Open-Meteo/ERA5, NASA POWER), an epidemiological archive (OpenDengue), user-defined sources (URL/upload), and the Gemini LLM for the plain-language explanation.

10 Validation

The pipeline design is validated against dengue in Thailand and kept general enough to apply – without architectural change – to further vector-borne diseases and to all 39 countries currently registered with sufficient epidemiological data coverage.