Entwurf: Motivation und literaturbasierte Anforderungsanalyse

LLM-gestützte Integration von Klima- und Gesundheitsdaten

Sergi Koniashvili
Bachelorarbeit Informatik, Universität Bremen

Stand: 1. November 2026 – Diskussionsgrundlage

Hinweis: Dieser Entwurf zeigt den geplanten Aufbau sowie erste Fassungen von Kapitel 1 und Kapitel 3. Rot markierte Stellen sind noch nicht belegt bzw. offen. Zitierstil vorläufig Autor-Jahr (siehe Frage in Abschnitt 3.5).

Geplante Gliederung der Arbeit

1. Einleitung (Motivation, Problemstellung, Zielsetzung, Aufbau)
2. Grundlagen (Klima und vektorübertragene Krankheiten; Datenquellen: Fallzahlen, Reanalyse-Klimadaten, Bevölkerung; ETL; LLMs)
3. Anforderungsanalyse (Ableitung aus Beispielpublikationen)
4. Verwandte Arbeiten und Werkzeuge [TODO: Werkzeuge aus offizieller Dokumentation prüfen]
5. Konzept und Architektur
6. Implementierung
7. Evaluation (Fallstudien CS1–CS3)
8. Diskussion, Grenzen und Ausblick
9. Fazit

1 Einleitung

1.1 Motivation

Die Wechselwirkung zwischen Klima und vektorübertragenen Krankheiten wie Dengue wird zunehmend mit datenbasierten Modellen untersucht. Ein aktuelles Beispiel ist die Studie von Suttirat et al. (2026), die monatliche Fallzahlen des Dengue-hämorrhagischen Fiebers (DHF) für 77 Provinzen Thailands über 20 Jahre (2003–2022) mit Klima-, Fernerkundungs- und sozioökonomischen Daten verknüpft und mit XGBoost und SHAP analysiert (S. 5–8). Lowe et al. (2021) untersuchen auf ähnliche Weise den Einfluss hydrometeorologischer Extreme und der Urbanisierung auf das Dengue-Risiko in 558 Mikroregionen Brasiliens (S. e211–e212).

Beiden Studien ist gemeinsam, dass vor der eigentlichen Modellierung eine umfangreiche Datenvorbereitung steht. Suttirat et al. beschreiben diese Schritte wie folgt:

> „Gridded climatic and remote-sensing data were spatially aggregated to the provincial level; lagged variables and bioclimatic indices were then derived from monthly provincial temperature and precipitation series. Socioeconomic data were obtained directly at the provincial level: the biennially reported household income series was linearly interpolated to fill missing years, and all socioeconomic series were then upsampled to monthly resolution by assigning each year's reported value (typically released at year-end) to every month of that year." (Suttirat et al., 2026, S. 4)

Diese Schritte sind nicht spezifisch für eine einzelne Studie. Lowe et al. (2021) führen weitgehend dieselben Schritte durch: Sie beziehen monatliche Fallzahlen aus dem nationalen Meldesystem, berechnen mit jährlichen Bevölkerungsschätzungen die Inzidenz pro 100 000 Einwohner, aggregieren gerasterte Klimadaten (Tmin, Tmax, PDSI) flächengewichtet auf die Untersuchungseinheiten und laden Klimadaten für ein zusätzliches Jahr vor der ersten Fallbeobachtung, „to allow for a lag period before the first dengue observation in January, 2001“ (S. e211). Auch Suttirat et al. erzeugen zeitverzögerte Variablen (Lags von 1–3 Monaten) für alle Klima- und Fernerkundungsvariablen (S. 7). Tabelle 1 stellt die Schritte beider Studien gegenüber.

Die Daten selbst sind oft öffentlich verfügbar, aber nicht unmittelbar analysebereit. Lowe et al. nutzen ausschließlich offene Daten (S. e218), jedoch aus fünf heterogenen Quellen mit unterschiedlichen Formaten und Auflösungen (monatlich, jährlich, statisch, 0,5°-Raster); die Zusammenstellung der Datenbank wird in den Autorenbeiträgen als eigene Aufgabe genannt (S. e218). Für die Gesundheitsdaten halten Clarke et al. (2024) bei der Beschreibung des OpenDengue-Datensatzes fest:

> „Dengue case data exists in multiple formats from a wide variety of sources that require various processing methodologies. […] Locating, extracting, processing and standardising data all takes time but is essential to enable reuse and re-analysis.“ (Clarke et al., 2024, S. 2)

OpenDengue löst damit die Sammlung der Fallzahlen. Die Verknüpfung mit Klimadaten, die Clarke et al. als einen Anwendungsfall nennen (S. 1, 9), bleibt jedoch Aufgabe der Forschenden.

Schließlich setzt dieser Arbeitsablauf Programmierkenntnisse voraus: Suttirat et al. führten die Datenaufbereitung mit Python (pandas) durch und berechneten bioklimatische Indikatoren mit dem R-Paket `dismo` (S. 5, 8). Für Forschende ohne Programmierkenntnisse, etwa im Bereich Public Health, stellt dies eine Hürde dar [TODO: Quelle zu fehlenden Programmier-/Data-Science-Kenntnissen im Public-Health-Bereich]. Bestehende Werkzeuge decken diese Schritte nur teilweise ab [TODO: Verwandte Arbeiten: Copernicus CDS, Google Earth Engine, DHIS2 Climate & Health, IRI ENACTS – jeweils aus offizieller Dokumentation belegen].

1.2 Problemstellung und Zielsetzung

Ziel dieser Arbeit ist ein System, das Forschenden die der Modellierung vorgelagerte Datenvorbereitung abnimmt – Quellensuche, Bereinigung, Harmonisierung, Zusammenführung und Dokumentation –, und zwar ohne Programmierkenntnisse und nachvollziehbar, sodass sie sich auf das eigentliche Modell konzentrieren können. Die Forschenden beschreiben den benötigten Datensatz (Krankheit, Region, Zeitraum, Klimavariablen) in einem Formular oder in natürlicher Sprache; ein Large Language Model (LLM) überführt die Anfrage in eine strukturierte Integrationsanfrage. Das System wählt geeignete Quellen, führt die Daten zu einer analysebereiten Tabelle zusammen, berechnet abgeleitete Größen (Inzidenz, zeitverzögerte Variablen) und protokolliert jeden Schritt.

Das System ist ausdrücklich *kein* Vorhersagemodell: Es bereitet Eingangsdaten für nachgelagerte datenbasierte Modelle vor. Ob es den manuellen Aufwand tatsächlich reduziert, wird in der Evaluation gemessen (Kapitel 7, Fallstudie CS1: derselbe Zieldatensatz wird manuell mit Python/pandas und mit dem System erstellt; erfasst werden Zeit, Anzahl manueller Schritte und Übereinstimmung der Ergebnisse).

1.3 Aufbau der Arbeit

[TODO: nach Festlegung der Gliederung ausformulieren]

3 Anforderungsanalyse

3.1 Vorgehen

Die Anforderungen werden aus Beispielpublikationen der datenbasierten Klima-Gesundheits-Modellierung abgeleitet. Für jede Publikation werden die vor der Modellierung durchgeführten Datenvorbereitungsschritte aus dem Methodenteil extrahiert. Jeder Schritt, der für die Bereitstellung eines analysebereiten Datensatzes notwendig ist, wird in eine Anforderung überführt oder begründet ausgeschlossen (Abgrenzung). Die Zuordnung Schritt → Publikation (mit Seitenangabe) → Anforderung wird in einer Traceability-Matrix festgehalten (Tabelle 2).

Grundlage sind derzeit drei Publikationen:

- **Suttirat et al. (2026)**: Dengue, Thailand, 77 Provinzen, 2003–2022, XGBoost/SHAP – Hauptfallstudie;
- **Lowe et al. (2021)**: Dengue, Brasilien, 558 Mikroregionen, 2001–2019, bayesianisches hierarchisches Modell – zeigt, dass die Schritte typisch sind;
- **Clarke et al. (2024)**: OpenDengue-Datensatz (Data Descriptor) – Anforderungen an Herkunft, Version und Vergleichbarkeit der Fallzahlen.

3.2 Datenvorbereitungsschritte in den Beispielpublikationen

Tabelle 1: Datenvorbereitung vor der Modellierung (Auszug)

Schritt	Suttirat et al. (2026)	Lowe et al. (2021)
Fallzahlen beziehen	monatliche DHF-Fälle, Bureau of Epidemiology (S. 5)	monatliche Meldefälle, SINAN/DATASUS (S. e211)
Verwaltungseinheiten harmonisieren	Bueng Kan in Nong Khai zusammengeführt (S. 5)	–
Klimavariablen beziehen	TerraClimate: u. a. Niederschlag, Tmin, Tmax (S. 5)	CRU TS 4.04: Tmin, Tmax, PDSI (S. e211)
Räumliche Aggregation	Raster auf Provinzebene gemittelt, Methode nicht angegeben (S. 5)	flächengewichtetes Mittel mit `exactextractr` (S. e211)
Zeitverzögerte Variablen	Lags 1–3 Monate (S. 7)	Lags 0–6 Monate (DLNM, S. e212)
Puffer für Lags	–	Klimadaten ein Jahr vor Beginn der Fallreihe (S. e211)
Inzidenz pro 100 000	ja (S. 7)	ja, mit jährlicher Bevölkerung (S. e211)
Jahreswerte → Monate	Jahreswert jedem Monat zugeordnet (S. 4–5)	nicht beschrieben
Fehlende Jahre auffüllen	Haushaltseinkommen linear interpoliert (S. 5)	–
Abgeleitete Indizes	19 bioklimatische Indikatoren (`dismo`, S. 5)	–
Werkzeuge	Python/pandas, R (S. 5, 8)	R, `exactextractr`, R-INLA (S. e211–e212)

3.3 Abgeleitete Anforderungen (Traceability-Matrix)

Tabelle 2: Zuordnung Schritt → Publikation → Anforderung

Schritt / Beobachtung	Beleg	Anforderung	Status
Inzidenz pro 100 000 als Zielgröße	Suttirat S. 7; Lowe S. e211	FR-17: Bevölkerungsdaten anbinden, jährliche Werte auf Monate interpolieren, Inzidenz berechnen	umgesetzt
Zeitverzögerte Klimavariablen	Suttirat S. 7 (1–3); Lowe S. e212 (0–6)	FR-23: Lag-Spalten 1–6 im Datensatz	umgesetzt
Klimadaten vor Beginn der Fallreihe	Lowe S. e211	FR-23: Lag-Puffer, damit keine Anfangszeilen verloren gehen	umgesetzt
Tmin/Tmax statt nur Mitteltemperatur	Suttirat S. 5; Lowe S. e211	FR-24: Tmin/Tmax als Mittel der täglichen Minima/Maxima	umgesetzt
Unterschiedliche zeitliche Auflösungen	Suttirat S. 4–5	FR-20: Auflösungsharmonisierung [TODO: Unterschied diskutieren: Suttirat wiederholt Jahreswerte (Bestandsgröße), FR-20 erhält Summen (Zählgröße)]	umgesetzt
Herkunft muss nachvollziehbar sein; Version angeben	Clarke S. 2, 4, 12	FR-25: Export mit Metadaten (Quellen, Lizenzen, Version, Schritte)	umgesetzt
Räumliche Abdeckung variiert zwischen Ländern (subnational nur für 40 von 102 Ländern)	Clarke S. 1, 8	FR-26: Datenlücken erkennen und begründen, nicht automatisch füllen	umgesetzt
Vergleichbarkeit zwischen Quellen beurteilen	Clarke S. 2	FR-27: zwei Quellen im Überlappungszeitraum vergleichen	umgesetzt
Zusammenhänge explorativ prüfen	Lags: Suttirat S. 7; Lowe S. e212	FR-19: Kreuzkorrelationen Lag 0–3 (Pearson, Spearman)	umgesetzt

Zu FR-19 ist eine Grenze festzuhalten: Korrelationen erfassen keine nichtlinearen Schwelleneffekte, wie sie Suttirat et al. fanden (etwa 21 °C für Tmin mit Lag 1 und 32 °C für Tmax mit Lag 3, S. 12); Lowe et al. betonen, dass der Einfluss des Klimas „complex, non-linear, and often delayed“ ist (S. e211). Die Korrelationen dienen daher nur der explorativen Datenprüfung, nicht der Modellierung.

3.4 Anforderungen ohne direkten Literaturbezug

Der ursprüngliche Anforderungskatalog (FR-01 bis FR-22) entstand vor der Literaturanalyse. Ein Teil davon lässt sich nachträglich begründen (FR-17, FR-19, FR-20, siehe oben). Weitere Anforderungen ergeben sich aus dem Ziel „ohne Programmierkenntnisse“ (natürlichsprachliche Anfrage FR-01, verständliche Erklärungen FR-09, Chat-Assistent FR-13, Weltkarte FR-22, PDF-Bericht FR-21) und aus Vorgaben der Betreuer (u. a. FR-03 bis FR-08).

Frage an die Betreuer: Sollen diese Anforderungen als Usability-Anforderungen mit dem Ziel „ohne Programmierung“ begründet oder aus der Arbeit gestrichen werden?

3.5 Abgrenzung

Folgende Schritte aus den Beispielpublikationen werden bewusst nicht umgesetzt; sie werden in Kapitel 8 als Grenzen diskutiert:

- subnationale Einheiten und räumliche Aggregation von Rasterdaten (Suttirat S. 5; Lowe S. e211) – das System nutzt einen repräsentativen Punkt pro Land;
- Harmonisierung sich ändernder Verwaltungseinheiten (Suttirat S. 5);
- bioklimatische Indikatoren und Fernerkundungsdaten (Suttirat S. 5);
- automatisches Auffüllen von Lücken aus einer anderen Quelle: Fallzahlen verschiedener Quellen beruhen auf unterschiedlichen Falldefinitionen – OpenDengue zählt alle gemeldeten Fälle (Clarke S. 5), Suttirat et al. nur DHF (S. 5) –, sodass eine verdeckte Mischung die Vergleichbarkeit beeinträchtigen würde. Das System erkennt Lücken (FR-26) und bietet einen expliziten Quellenvergleich an (FR-27).

Offene Fragen für die Besprechung

1. Entspricht die Argumentationskette der Motivation (Modelle → aufwendige, typische Datenvorbereitung → Programmierkenntnisse nötig → System) Ihrer Vorstellung?
2. Reichen zwei Modellierungsstudien und ein Data Descriptor, oder sollen weitere Studien (z. B. Malaria) aufgenommen werden?
3. Ist die Traceability-Matrix als Form der Anforderungsableitung geeignet?
4. Welcher Zitierstil wird erwartet (Autor-Jahr oder numerisch)?
5. Gliederung: Passt die Position von „Verwandte Arbeiten“ nach der Anforderungsanalyse?

Literatur (Entwurf)

Clarke, J., Lim, A., Gupte, P., Pigott, D. M., van Panhuis, W. G., & Brady, O. J. (2024). A global dataset of publicly available dengue case count data. *Scientific Data*, 11, 296. https://doi.org/10.1038/s41597-024-03120-7

Lowe, R., Lee, S. A., O'Reilly, K. M., Brady, O. J., Bastos, L., Carrasco-Escobar, G., et al. (2021). Combined effects of hydrometeorological hazards and urbanisation on dengue risk in Brazil: a spatiotemporal modelling study. *The Lancet Planetary Health*, 5(4), e209–e219. https://doi.org/10.1016/S2542-5196(20)30292-8

Suttirat, P., Chadsuthi, S., Aekthong, S., Rocklöv, J., Bicout, D. J., Haddawy, P., Su Yin, M., Lawpoolsri, S., & Modchang, C. (2026). Machine learning reveals temperature as a key predictor of dengue risk across Thailand's provinces: A 20-year analysis. *PLoS Neglected Tropical Diseases*, 20(7), e0014590. https://doi.org/10.1371/journal.pntd.0014590