LLM-Climate-Health

ტექნიკური დოკუმენტაცია და ლექსიკონი

LLM-ზე დაფუძნებული ETL პლატფორმა კლიმატისა და ჯანმრთელობის მონაცემთა ინტეგრაციისთვის

საბაკალავრო ნაშრომი

ბრემენის უნივერსიტეტი – ინფორმატიკის ფაკულტეტი

ავტორი: სერგი კონიაშვილი

თარიღი: November 1, 2026

ეს დოკუმენტი აღწერს პლატფორმის არქიტექტურას, მონაცემთა ინტეგრაციის პროცესს და მასში გამოყენებულ ძირითად ცნებებს – საბაკალავრო ნაშრომში გამოსაყენებლად.

Contents

1 შესავალი 2

2 სისტემის არქიტექტურა 2
2.1 Backend-ის მოდულები 2

3 მონაცემთა ინტეგრაციის პროცესი (ETL) 3
3.1 მოსახლეობა და ინციდენტობა 3
3.2 დროითი დაყოვნება და კლიმატის Lag-ბუფერი 3
3.3 გამჭვირვალობა და კეშირება 4
3.4 მონაცემთა სისრულის შემოწმება და ხარვეზების აღმოჩენა (FR-26) 4
3.5 მონაცემთა წყაროების ემპირიული შედარება (FR-27) 5

4 ბუნებრივი ენით მოთხოვნის ინტერპრეტაცია 6
4.1 დახურული ლექსიკონი გამონაგონის თავიდან ასაცილებლად 6

5 საკვანძო ცნებები კლიმატურ მონაცემებში 6
5.1 რეანალიზი (Reanalysis) 6
5.2 რეანალიზი vs. მოდელის პროგნოზი (Projection) 6
5.3 Bias Correction (მიკერძოების კორექცია) 7
5.4 ემისიის სცენარები (Emission Scenarios) 7
5.5 მინიმალური და მაქსიმალური ტემპერატურა (Tmin / Tmax) 7
5.6 სივრცული და დროითი შეთანხმება (Join) 7

6 გამოყენებული მონაცემთა წყაროები 7
6.1 რეგიონულად შეზღუდული წყარო: TMD 8

7 დაავადების მონაცემთა წყაროების ცოცხალი ძებნა 8
7.1 ორი წყარო-კატალოგი 8
7.2 როგორ ჯდება არსებულ არქიტექტურაში 9
7.3 შეზღუდვები 9

8 მონაცემთა ინტელექტუალური ჰარმონიზაცია და გამჭვირვალობის ჟურნალი 10

9 მრავალგანზომილებიანი ინტერაქტიული ვიზუალიზაცია და KPI მეტრიკები 10

10 ამჟამად განხორციელებული ფუნქციები 10

11 შემდეგი ნაბიჯები 11

1 შესავალი

ბევრი დაავადება კლიმატზეა დამოკიდებული – მათი გადამტანები (მაგალითად, კოღოები) მგრძნობიარენი არიან ტემპერატურის, ნალექისა და ტენიანობის მიმართ. ეს ნიშნავს, რომ კლიმატური მონაცემები შეიძლება გამოყენებულ იქნას როგორც ადრეული ინდიკატორი დაავადების აფეთქების რისკისთვის.

ამ პროექტის მიზანია შეიქმნას ზოგადი დანიშნულების პლატფორმა, რომელიც საშუალებას მისცემს მომხმარებელს – პროგრამირების ან კლიმატოლოგიის ცოდნის გარეშე – ბუნებრივი ენით ჩამოაყალიბოს მოთხოვნა (დაავადება, რეგიონი, კლიმატური ცვლადები) და მიიღოს ანალიზისთვის მზა, ურთიერთდაკავშირებული მონაცემები. დიდი ენობრივი მოდელი (LLM) ამ მოთხოვნას გარდაქმნის შესრულებად ინტეგრაციის გეგმად და ყოველ ნაბიჯს მარტივი ენით უხსნის მომხმარებელს.

მნიშვნელოვანია: პლატფორმა აწარმოებს მონაცემებს, არა პროგნოზებს. შედეგი გამოიყენება როგორც შემავალი მონაცემები შემდგომი დაავადების მოდელებისთვის.

ვალიდაციის სცენარი

პროექტი ვალიდირებულია დენგეს ცხელების მაგალითზე ტაილანდში, თუმცა არქიტექტურა შექმნილია ისე, რომ იგივე ლოგიკა ვრცელდებოდეს სხვა ვექტორგადამტან დაავადებებზეც (მალარია, ქოლერა, ლაიმის დაავადება) და ნებისმიერ რეგიონზე, სადაც არსებობს საკმარისი მონაცემები.

2 სისტემის არქიტექტურა

პლატფორმა აგებულია სამი ფენისგან: frontend (Flutter), backend (Python/FastAPI) და გარე მონაცემთა წყაროები. Flutter არჩეულია იმიტომ, რომ ერთი კოდით შესაძლებელია აპლიკაციის აგება ვებისთვის, მობილურისთვის და დესკტოპისთვისაც – ეს მნიშვნელოვანია, რადგან პლატფორმა გამიზნულია ფართო ხელმისაწვდომობისთვის ბმულის საშუალებით.

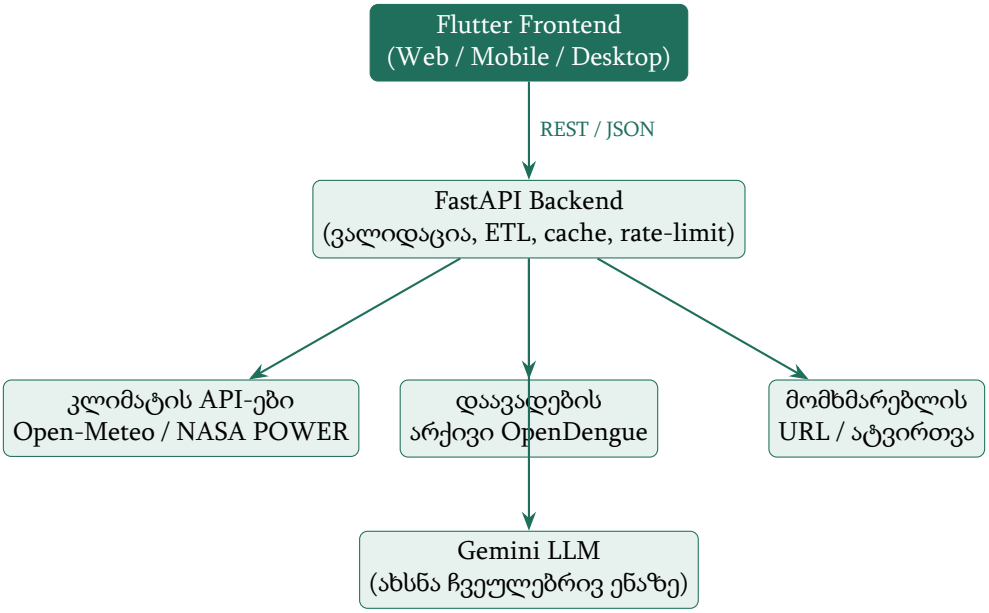


Figure 1: პლატფორმის მაღალი დონის არქიტექტურა

2.1 Backend-ის მოდულები

- config – გარემოს ცვლადები, მხარდაჭერილი რეგიონების/წყაროების რეესტრი;

- services/dengue – დაავადების შემთხვევების მონაცემები (OpenDengue, URL, ატვირთვა);
- services/climate – კლიმატური რეანალიზის მონაცემები (Open-Meteo, NASA POWER);
- services/etl – ორკესტრაცია: მოძიება, აგრეგირება, დაკავშირება;
- services/llm – Gemini API-სთან კომუნიკაცია, rate-limiting;
- services/cache – შედეგების დროებითი შენახვა და last_verified დროის ნიშნულის დამატება.

3 მონაცემთა ინტეგრაციის პროცესი (ETL)

ყოველი მოთხოვნა გადის შემდეგ ეტაპებს, რომლებიც მომხმარებელს ჩანს ეკრანზე – ეს იმისთვისაა, რომ მომხმარებელმა დარწმუნებით იცოდეს, რომ მისი ბრძანება სწორად შესრულდა.

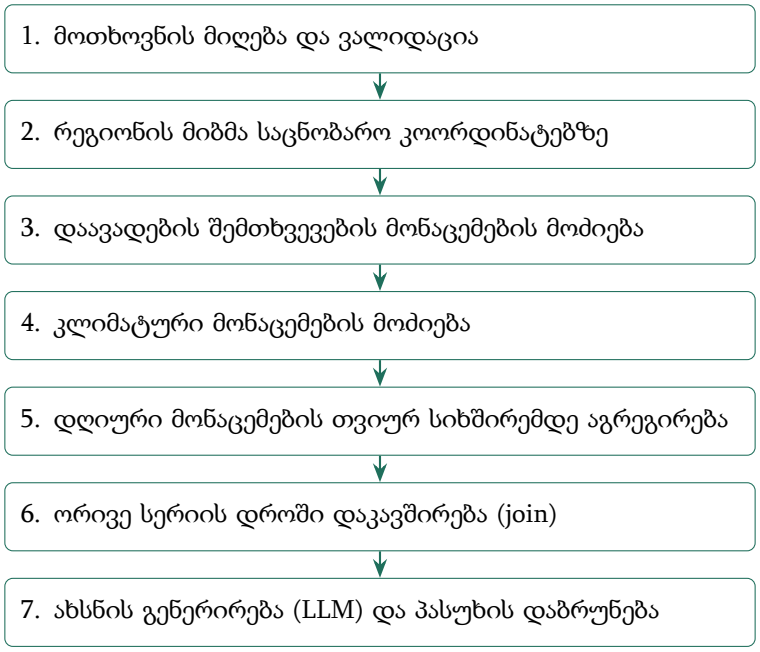


Figure 2: ETL პროცესის ეტაპები (ერთი მოთხოვნისთვის)

3.1 მოსახლეობა და ინციდენტობა

ინციდენტობა (შემთხვევები 100 000 მოსახლეზე) მოსახლეობის რიცხვს მოითხოვს, რომელიც წყაროებში (მსოფლიო ბანკი, UN WPP) მხოლოდ წლიურია. თვიური და დღიური რეზოლუციისას სისტემა ყოველი წლის მნიშვნელობას წლის შუა წერტილზე (1 ივლისი) აბამს და მათ შორის წრფივად ინტერპოლირებს. ასე მოსახლეობა თანდათან იცვლება და წლის საზღვარზე (დეკემბერი $\rightarrow$ იანვარი) ხელოვნური ნახტომი აღარ ჩნდება, რომელიც ინციდენტობაშიც აისახებოდა. ხელმისაწვდომი წლების გარეთ უახლოესი წლის მნიშვნელობა რჩება: ტრენდის გაგრძელება მონაცემის გამოგონება იქნებოდა. ეს ნაბიჯი ნაბიჯების სიაშიც ჩანს. იგივე მიდგომას იყენებს Suttirat et al. (2026) წლიური კოვარიატებისთვის.

მაგალითი (ტაილანდი): ადრე 2009-12 $\rightarrow$ 2010-01 მოსახლეობა ერთბაშად $+458\,367$-ით იზრდებოდა, ახლა ყოველთვიურად დაახლოებით $+38\,000$-ით.

3.2 დროითი დაყოვნება და კლიმატის Lag-ბუფერი

ეპიდემიოლოგიური მოდელებისთვის (Suttirat et al. 2026, Lowe et al. 2021) კრიტიკულია დაავადების შემთხვევების კავშირი წინა პერიოდების კლიმატურ პირობებთან (ინკუბაციისა და კოღოს

განვითარების ციკლები). სისტემა საშუალებას აძლევს მომხმარებელს მოითხოვოს დაყოვნებული ცვლადები (`lag_periods`, 1–6 პერიოდი). მაგალითად, თვიურ ჭრილში Lags 1 და 3 ქმნის სვეტებს `temperature_lag1`, `temperature_lag3`, `precipitation_lag1` და `precipitation_lag3`.

საწყისი რიგების დაუკარგავად გამოსათვლელად სისტემა იყენებს Lag-ბუფერს: კლიმატის მონაცემები მოთხოვნილ `start_date`-ზე `max(lag_periods)` პერიოდით ადრე ამოიღება (Lowe et al. 2021). Lags გამოითვლება ამ გაფართოებულ სერიაზე, ხოლო შედეგი იჭრება ზუსტად მოთხოვნილ საწყის თარიღამდე. ამგვარად, გამომავალი ცხრილის პირველივე რიგს (მაგ. 2010-01) გააჩნია სრულფასოვანი მნიშვნელობები წინა თვეებიდან (2009-12 და 2009-10) და არცერთი სათვალთვალო რიგი არ იკარგება.

3.3 გამჭვირვალობა და კეშირება

თითოეული ნაბიჯი ტექსტურად ფორმდება და უბრუნდება frontend-ს, ისე რომ მომხმარებელს შეუძლია ნახოს ზუსტად რა მოხდა. თუ იგივე მოთხოვნა მეორდება 15 წუთის განმავლობაში, სისტემა უბრუნებს კეშირებულ შედეგს (გარე API-ების ზედმეტი დატვირთვის თავიდან ასაცილებლად) და უჩვენებს ბოლო გადამოწმების დროის ნიშნულს (`last_verified`), რომ მომხმარებელმა იცოდეს რამდენად ახალია მონაცემი.

წარმომავლობა ექსპორტში (FR-25). გადმოწერილი ფაილი თავად უნდა პასუხობდეს კითხვებს: რა, სად, რომელი პერიოდი, საიდან, რა ლიცენზიით, როდის და პროგრამის რომელი ვერსიით (Clarke et al. 2024, გვ. 4, 12). ამიტომ JSON ექსპორტი ასეთი სტრუქტურისაა: `{"metadata": {...}, "data": [...]}`. CSV ფაილი ჩვეულებრივ ცხრილად რჩება (Excel და pandas მას ზედმეტი პარამეტრების გარეშე კითხულობს), ხოლო მის გვერდით მეორე ფაილი, `<  >_metadata.json`, ჩამოიტვირთება. მეტამონაცემებში წერია: დაავადება, რეგიონი, მოთხოვნის პარამეტრები, ცხრილის პერიოდი და პერიოდი, რომელსაც შემთხვევები რეალურად ფარავს (მაგ. OpenDengue-ში ტაილანდი 2009 წლიდან იწყება), წყაროები, თითოეული წყაროს ლიცენზია, დამუშავების ნაბიჯები, ჩამოტვირთვისა და ექსპორტის დრო, სისტემის ვერსია (`APP_VERSION` ან git commit) და შენიშვნა, რომ შემთხვევის განსაზღვრება ქვეყნებსა და დროში იცვლება. ლიცენზიები შემოწმდა თითოეული მომწოდებლის ოფიციალურ გვერდზე (2026-11-01): OpenDengue V1.3 – CC BY 4.0 (ადრეული ვერსიები CC BY-SA), Open-Meteo – CC BY 4.0 (ERA5: Copernicus-ის ლიცენზია), World Bank – CC BY 4.0, UN WPP – CC BY 3.0 IGO, WHO GHO – WHO-ს საკუთარი პირობები, NASA POWER – ლიცენზია მითითებული არ არის (ითხოვს ციტირებას). იგივე ინფორმაცია PDF ანგარიშშიც ჩანს.

ახსნის ტექსტი (`explanation`) ყოველთვის Gemini-ს მეშვეობით გენერირდება, მაგრამ თუ API-ის გამოძახება ჩავარდება (მაგ. rate limit ან დროებითი მიუწვდომლობა), სისტემა წინასწარ მომზადებულ, ზოგად ტექსტს აბრუნებს ისე, რომ მომხმარებელმა საერთოდ არაფერი არ დაინახოს ცარიელი ადგილის ნაცვლად. რომ ეს ჩანაცვლება არასდროს გავიდეს ნამდვილ, კონკრეტულ მოთხოვნაზე მორგებულ ტექსტად, პასუხს დაემატა ცალკე ველი `explanation_source` (`"llm"` ან `"fallback"`) – frontend პირდაპირ აჩვენებს, რომელი შემთხვევა მოხდა.

3.4 მონაცემთა სისრულის შემოწმება და ხარვეზების აღმოჩენა (FR-26)

თუ მოთხოვნილი პერიოდის განმავლობაში რომელიმე ცვლადს (შემთხვევები, მოსახლეობა, ტემპერატურა ან ნალექი) მონაცემები აკლია, სისტემა ავტომატურად ამოწმებს სისრულეს (`backend/app/services/coverage.py`). თითოეული სვეტისთვის გამოითვლება: პერიოდების საერთო რაოდენობა, მონაცემიანი პერიოდები, გამოტოვებული პერიოდების რიცხვი, პროცენტული წილი და უწყვეტი გამოტოვებული ინტერვალები (მაგ. 2005-01 – 2008-12). Lag-ბუფერის თვეები ანალიზში არ შედის (მხოლოდ მოთხოვნილი პერიოდი ფასდება).

დეტერმინისტული მიზეზის დადგენა. იმის ნაცვლად, რომ LLM-მა მიზეზი გამოიცნოს (ჰალუცინაციის რისკი), სისტემა წესებზე დაფუძნებულ დეტერმინისტულ ლოგიკას იყენებს:

- `"outside_source_coverage"`: მოთხოვნილი პერიოდი სცილდება წყაროს ცნობილ დაფარვას (მაგ. OpenDengue ტაილანდისთვის იწყება 2009-01-დან; თუ მოთხოვნა იყო 2005-დან, ხარვეზი წყაროს დროითი საზღვრების გარეთაა).

- `"gaps_inside_source"`: მონაცემები აკლია წყაროს დაფარვის შიდა ინტერვალში.
- `"not_provided_by_source"`: არჩეული წყარო ამ ცვლადს საერთოდ არ აწვდის (მაგ. TMD არ შეიცავს ტემპერატურას). ეს ნეიტრალურად აღინიშნება (წითელი გაფრთხილების გარეშე).
- `"unknown"`: სხვა გაურკვეველი მიზეზი.

მომხმარებლის ინტერფეისი და ქმედებები. frontend-ში შედეგების ზედა ნაწილში ჩნდება `DataCoverageCard` (თუ ხარვეზია). ბარათი აჩვენებს პროგრესის ხაზებს თითოეული ცვლადისთვის და სთავაზობს ერთ-კლიკიან ქმედებებს: სხვა წყაროს ძებნა (`SourceSearchDialog` ან `PopulationSearchDial` პერიოდის მორგება ხელმისაწვდომ მონაცემებზე (ფორმის ველების ავტომატური შევსება) ან ალტერნატიული კლიმატის წყაროს არჩევა (ERA5 vs NASA POWER). A20 პრინციპის თანახმად, სისტემა არასდროს არ ავსებს ხარვეზებს ხელოვნური ან კოპირებული მნიშვნელობებით. სისრულის მეტრიკები ასევე ექსპორტირდება მეტამონაცემებში (`data_coverage`) და PDF ანგარიშში.

3.5 მონაცემთა წყაროების ემპირიული შედარება (FR-27)

კლიმატისა და ჯანდაცვის ინტეგრაციაში კვლევის ხარისხი დამოკიდებულია გამოყენებული მონაცემთა წყაროების თავსებადობაზე. მკვლევრისთვის აუცილებელია იმის შემოწმება, რამდენად ეთანხმება ერთმანეთს ალტერნატიული მეტეოროლოგიური რეანალიზები (მაგ. Open-Meteo ERA5 და NASA POWER MERRA-2) ან ეპიდზედამხედველობის მონაცემთა ნაკრებები (Clarke et al. 2024; RECOMMENDATIONS A19).

ამ მიზნით პლატფორმას დაემატა წყაროების ემპირიული შედარების სერვისი (`POST /api/compare-sou` `services/source_comparison.py`):

- ორმხრივი მეტრიკები თანხვედრ პერიოდში: სისტემა განსაზღვრავს ორ წყაროს შორის საერთო დროით ინტერვალს და თითოეული საბაზისო ცვლადისთვის (საშუალო, მინიმალური, მაქსიმალური ტემპერატურა, ნალექი, შემთხვევები; Lag-სვეტების გარეშე) ითვლის პირსონის r-ს, ფორმატირებულ p-value-ს (`statistics.format_p_value`), საშუალო სხვაობას ($B - A$), საშუალო აბსოლუტურ სხვაობას (MAD) და ფარდობით MAD%-ს საბაზისო სერიის საშუალოსთან მიმართებით.
- დეტერმინისტული ევრისტიკული შეფასება (Rule of Thumb):
  - ძალიან მსგავსი (`very_similar`): $r \geq 0.90$ და ფარდობითი MAD $\leq 10\%$;
  - მსგავსი (`similar`): $r \geq 0.70$ და ფარდობითი MAD $\leq 25\%$;
  - მკაფიოდ განსხვავებული (`clearly_different`): სხვა დანარჩენი შემთხვევები;
  - ძალიან ცოტა წერტილი (`too_few_points`): თანხვედრი წერტილების რაოდენობა $n < 6$.
- სეზონური ციკლისა და ეპიდზედამხედველობის მეთოდური შენიშვნა: კლიმატის სერიების შედარებისას სისტემა მკაფიოდ უთითებს: „მაღალი r ნაწილობრივ ასახავს საერთო სეზონურ ციკლს; საშუალო სხვაობა გვიჩვენებს სისტემურ ცდომილებას.” ხოლო შემთხვევათა შედარებისას გათვალისწინებულია ეპიდზედამხედველობისა და შემთხვევის განსაზღვრების განსხვავებები (Clarke et al. 2024), რის გამოც უპირატესობა ენიჭება დროითი დინამიკის მსგავსებას (r) და არა აბსოლუტურ დონეს. პლატფორმა ხაზგასმით აფრთხილებს მომხმარებელს, რომ შედარება საორიენტაციოა და არ წარმოადგენს სტატისტიკური მნიშვნელოვნობის ტესტს.
- არადესტრუქციულობა და შესრულების სისწრაფე: შედარება იძახებს `run_integration`-ს პირდაპირ, `lag_periods=[]` პარამეტრით და LLM-ის ახსნის გარეშე, რაც უზრუნველყოფს მყისიერ, დეტერმინისტულ პასუხს Gemini API-ის კვოტის ხარჯვის გარეშე. მთავარი ინტეგრირებული მონაცემთა ბაზა, ქეში და ექსპორტი რჩება სრულიად ხელუხლებელი.
- ალტერნატიული წყარო B-ს მოქნილი არჩევა: მომხმარებელს შეუძლია წყარო B-ს მრავალმხრივი კონფიგურაცია:

  - კლიმატის მონაცემები: Open-Meteo ERA5, NASA POWER MERRA-2, TMD (მხოლოდ ტაილანდის რეგიონისთვის და როდესაც API გასაღებები კონფიგურირებულია, რასაც სისტემა ავტომატურად ამოწმებს `/api/options`-ის `tmd_configured` ველით), ან მომხმარებლის მიერ ლოკალურად ატვირთული კლიმატის CSV ფაილი.
  - შემთხვევათა მონაცემები: WHO GHO ინდიკატორის მოძიება და არჩევა ინტეგრირებული საძიებო დიალოგით (`SourceSearchDialog`), მორგებული URL (`custom_url`), ან ლოკალურად ატვირთული ეპიდემიოლოგიური CSV ფაილი.

- WHO GHO წლიური შედარება მხოლოდ სრული წლებისთვის: რადგან WHO GHO მხოლოდ წლიურ მონაცემებს აწვდის, ორივე წყარო შედარებულია წლიურ დონეზე (`aggregation="yearly"`). წლიური მონაცემების თვეებად ხელოვნური დეზაგრეგაცია აკრძალულია. საბაზისო წყარო A-ს თვიური მონაცემები (მაგ. OpenDengue) შეჯამდება მხოლოდ იმ კალენდარული წლებისთვის, სადაც მოთხოვნილ ინტერვალში წარმოდგენილია 12-ვე სრული თვე. არასრული წლები (მაგ. პირველი ან ბოლო არასრული წელი, ან შიდა ხარვეზი) გამოირიცხება ხელოვნური შემცირების თავიდან ასაცილებლად, აისახება პასუხის `excluded_years` სიაში და მკაფიოდ ეცნობება მკვლევარს. წლიურ შედარებაზე წერტილების მცირე რაოდენობისას ($n < 6$) ჩნდება გაფრთხილება.

- მულტიპარტ ატვირთვის ენდპოინტი (**`POST /api/compare-sources/upload`**): ფაილის სახით წყარო B-ს შედარებისთვის შეიქმნა ცალკე ენდპოინტი, რომელიც იღებს `request` ველს (JSON სტრიქონი) და `file`-ს (მაქსიმუმ 10 MB, გადაჭარბებაზე 413). ატვირთული ფაილი გამოიყენება მხოლოდ მეხსიერებაში კონკრეტული შედარებისთვის და არსად ინახება. თუ თავად საბაზისო წყარო A იყო ატვირთული ფაილი, ენდპოინტი აბრუნებს 400 შეცდომას.

- მომხმარებლის ინტერფეისი: შედეგების ეკრანზე ჩამოტვირთვის ზოლის გვერდით განთავსებულია ღილაკი „წყაროების შედარება”, რომელიც ხსნის მოდალურ დიალოგს (`SourceComparisonDialog`) კლიმატის/შემთხვევების გადამრთველით, წყარო B-ს არჩევის (WHO GHO ძებნა, URL, CSV ატვირთვა), სრული წლების შედარების ბანერით, გაფრთხილებით, Sparkline-ვიზუალიზაციითა და დეტალური მეტრიკების ჩაშლადი ცხრილით.

4 ბუნებრივი ენით მოთხოვნის ინტერპრეტაცია

თავდაპირველად მომხმარებელი მოთხოვნას მხოლოდ სტრუქტურირებული ფორმის (dropdown-ების და თარიღის ველების) მეშვეობით ავსებდა. ამას დაემატა დამატებითი, არასავალდებულო გზა: მომხმარებელს შეუძლია მოთხოვნა თავისუფალი ტექსტით აღწეროს (მაგ. „დენგე ტაილანდში 2015-დან 2023 წლამდე, ყოველთვიურად, ტემპერატურა და ნალექი”), და Gemini LLM ცდილობს ამის საფუძველზე ფორმის ველების ავტომატურად შევსებას (**`POST /api/parse-request`**).

უსაფრთხოების პრინციპი: მხოლოდ შევსება, არასდროს გაშვება

ბუნებრივი ენის პარსინგი მხოლოდ წინასწარ ავსებს ფორმას – ის არასდროს უშვებს ETL პროცესს პირდაპირ. მომხმარებელს ყოველთვის შეუძლია შევსებული ველების გადამოწმება და საჭიროების შემთხვევაში ხელით შესწორება, სანამ „Run integration”-ზე დააჭერს. ეს ინარჩუნებს პლატფორმის ძირითად პრინციპს: LLM ხსნის და ეხმარება, მაგრამ არასდროს იღებს გადაწყვეტილებას მომხმარებლის ნაცვლად.

4.1 დახურული ლექსიკონი გამონაგონის თავიდან ასაცილებლად

LLM-ს არ აქვს თავისუფლება ნებისმიერი მნიშვნელობის შემოთავაზების – prompt-ში პირდაპირ ეწერება ყველა დაშვებული დაავადება, რეგიონი, ცვლადი, აგრეგაცია და კლიმატის წყარო, და მოდელს მოეთხოვება აირჩიოს მხოლოდ ამ სიებიდან, ან დატოვოს ველი ცარიელი (`null`), თუ ტექსტში ცალსახად არ ჩანს. პასუხის დამუშავებისას (`_coerce_parsed_json`) ყოველი მნიშვნელობა ხელახლა მოწმდება backend-ის კოდში – თუ მოდელმა მაინც შემოგვთავაზა

ამ სიების გარეთა მნიშვნელობა, ის იშლება (`None`-ად იქცევა) და ეს ფაქტი მომხმარებელს უჩნდება „notes" ველში ახსნილი დაშვების სახით. ამგვარად, არასწორად ამოცნობილი დაავადება ან რეგიონი ვერასდროს მიაღწევს პირდაპირ ETL პროცესამდე.

5 საკვანძო ცნებები კლიმატურ მონაცემებში

ეს თავი გამოსადეგია, როგორც მოკლე სასწავლო მასალა – განმარტავს ტერმინებს, რომლებსაც პლატფორმა იყენებს.

5.1 რეანალიზი (Reanalysis)

რეანალიზი არის წარსული ამინდის მონაცემების მეცნიერულად აღდგენილი, თანმიმდევრული სურათი. ის იქმნება ისტორიული დაკვირვებების (მეტეოსადგურები, თანამგზავრები, ხომალდები) და ფიზიკური ამინდის მოდელის შერწყმით. ეს არ არის ერთი კონკრეტული სადგურის ნედლი მონაცემი – ის წარმოადგენს საუკეთესო შეფასებას იმისა, თუ როგორი იყო ატმოსფერო კონკრეტულ ადგილას და დროს. პლატფორმა იყენებს ECMWF ERA5 რეანალიზს (Open-Meteo-ს საშუალებით) და NASA POWER-ს (MERRA-2 რეანალიზზე დაფუძნებული).

5.2 რეანალიზი vs. მოდელის პროგნოზი (Projection)

რეანალიზი აღწერს წარსულს და კორექტირდება რეალურ დაკვირვებებზე. მოდელის პროგნოზი (მაგ. CMIP6/CORDEX სცენარები) კი სიმულირებს მომავალ კლიმატს ემისიების სხვადასხვა დაშვებით და არ არის დაკავშირებული კონკრეტულ დაკვირვებულ მოვლენებთან. ამჟამინდელი იმპლემენტაცია იყენებს მხოლოდ ისტორიულ რეანალიზს (`scenario=historical`); მომავალი პროგნოზების ინტეგრაცია დაგეგმილია შემდეგ ეტაპზე.

5.3 Bias Correction (მიკერძოების კორექცია)

კლიმატის მოდელებს ხშირად აქვთ სისტემატური გადახრა რეალობისგან (მაგალითად, მუდმივად აჭარბებენ ნალექის რაოდენობას კონკრეტულ რეგიონში). Bias correction არის სტატისტიკური მეთოდი, რომელიც ასწორებს ამ გადახრას ისტორიულ დაკვირვებებთან შედარებით, სანამ მონაცემი გამოყენებული იქნება შემდგომი ანალიზისთვის. ეს განსაკუთრებით მნიშვნელოვანია მაშინ, როცა პროგნოზული (არა-რეანალიზის) მონაცემები გამოიყენება.

5.4 ემისიის სცენარები (Emission Scenarios)

ეს არის დაშვებები მომავალი სათბურის გაზების გამონაბოლქვის შესახებ (მაგ. SSP1-2.6 – დაბალი ემისია, SSP5-8.5 – მაღალი ემისია), რომლებზეც დაფუძნებულია კლიმატის მომავალი პროგნოზები. რადგან მომავალი ზუსტად უცნობია, მეცნიერები იყენებენ რამდენიმე სცენარს პარალელურად.

5.5 მინიმალური და მაქსიმალური ტემპერატურა (Tmin / Tmax)

ეპიდემიოლოგიური კვლევების მიხედვით (მაგ. Suttirat et al., 2026), დენგეს ვირუსის გადაცემის მოდელირებაში გადამწყვეტ როლს ასრულებს არა მხოლოდ საშუალო ტემპერატურა, არამედ დღიური ექსტრემუმები: მინიმალური (`temperature_min`) და მაქსიმალური (`temperature_max`) ტემპერატურა (განსაკუთრებით 1 და 3 თვიანი დაყოვნებით, tmin_{-1} და tmax_{-3}). პლატფორმა ამ მონაცემებს იღებს Open-Meteo ERA5-იდან (ველები `temperature_2m_min`, `temperature_2m_max`) და NASA POWER-იდან (პარამეტრები `T2M_MIN`, `T2M_MAX`). დროითი აგრეგაციისას (დღიდან თვემდე, წლამდე ან ათწლეულამდე), სისტემა გამოთვლის პერიოდის განმავლობაში დღიური მინიმუმების (ან მაქსიმუმების) საშუალოს (mean of daily minima/maxima) და არა თვის აბსოლუტურ ექსტრემუმს. ზუსტად ასეა განმარტებული Lowe et al. (2021, გვ. e211) ცვლადი: „monthly mean daily minimum temperature". Suttirat et al. (2026) TerraClimate-ის უკვე თვიური Tmin/Tmax

გამოიყენეს და დღიურ მონაცემებს თავად არ აგრეგირებდნენ. TMD წყაროს შემთხვევაში ტემპერატურული ველები რჩება ცარიელი (`null`), რადგან ეს ენდპოინტი მხოლოდ ნალექს იძლევა.

5.6 სივრცული და დროითი შეთანხმება (Join)

სხვადასხვა წყაროს მონაცემები განსხვავებული სივრცული (წერტილი, ბადე, რეგიონი) და დროითი (დღიური, თვიური, წლიური) გარჩევადობით მოდის. პლატფორმა კლიმატურ მონაცემებს დღიურიდან თვიურამდე აგრეგირებს (ტემპერატურა – საშუალო, ნალექი – ჯამი), რათა ის დაემთხვეს დაავადების შემთხვევების ჩვეულებრივ თვიურ ანგარიშგებას, შემდეგ კი აერთიანებს ორივეს საერთო თვე-წლის გასაღებით.

6 გამოყენებული მონაცემთა წყაროები

- OpenDengue – აკადემიური, საჯაროდ ხელმისაწვდომი დენგეს შემთხვევების არქივი (Clarke et al., 2024, Scientific Data). მოიცავს 39 ქვეყანას საკმარისი (12+ თვე) თვიური გარჩევადობით.
- Open-Meteo Historical Archive – ECMWF ERA5 რეანალიზზე დაფუძნებული, უფასო, გასაღების გარეშე ხელმისაწვდომი API.
- NASA POWER – ალტერნატიული სამეცნიერო კლიმატური წყარო (MERRA-2 რეანალიზი), ასევე გასაღების გარეშე ხელმისაწვდომი.
- Thai Meteorological Department (TMD) – ტაილანდის ეროვნული, ოფიციალური მეტეოროლოგიური სამსახურის API (`data.tmd.go.th`), ხელმისაწვდომი მხოლოდ ტაილანდისთვის (იხ. ქვემოთ).
- მომხმარებლის საკუთარი წყარო – URL ან ატვირთული CSV ფაილი, თუ მომხმარებელს სურს საკუთარი სამეცნიერო მონაცემების გამოყენება.

6.1 რეგიონულად შეზღუდული წყარო: TMD

ღია, გლობალური კლიმატის წყაროებისგან (Open-Meteo, NASA POWER) განსხვავებით, TMD მხოლოდ ტაილანდის ტერიტორიაზეა ხელმისაწვდომი და მოითხოვს რეგისტრაციას (`uid`/`ukey` წყვილი, უფასო, `data.tmd.go.th`-ზე). ეს შეზღუდვა კოდში ცალკე რეესტრშია აღწერილი (`CLIMATE_SOURCE_REGIONS`), რომელსაც backend ამოწმებს მოთხოვნის დროს – თუ მომხმარებელი TMD-ს სხვა რეგიონისთვის აირჩევს, მკაფიო 400 შეცდომას იღებს დაბნეული ან ცარიელი პასუხის ნაცვლად.

გულწრფელი შეზღუდვა: დაუდასტურებელი პასუხის სტრუქტურა

TMD-ს საჯარო დოკუმენტაცია აღწერს endpoint-ებს და საჭირო `uid`/`ukey` პარამეტრებს, მაგრამ არ აქვეყნებს ზუსტ JSON ველების სახელებს. შესაბამისად, პასუხის დამუშავების ლოგიკა (`_parse_tmd_response`) დაწერილია დოკუმენტაციაში აღწერილი ველების საფუძველზე და საჭიროებს რეალურ smoke-ტესტს, როგორც კი წვდომის მონაცემები (`TMD_API_UID`/`TMD_API_UKEY`) დარეგისტრირდება. ეს გაურკვევლობა შეგნებულად არის იზოლირებული ერთ ფუნქციაში, რომ საჭიროების შემთხვევაში გასწორება ერთ ადგილას შემოიფარგლოს.

7 დაავადების მონაცემთა წყაროების ცოცხალი ძებნა

თავდაპირველ ვერსიაში თითო დაავადებას მხოლოდ ერთი, კოდში ჩაშენებული წყარო ჰქონდა მიბმული – მომხმარებელს არჩევანის საშუალება არ ჰქონდა. ამის გამოსასწორებლად დაემატა ცოცხალი ძებნის ფუნქცია: backend-ი რეალურ დროში ეკითხება ორ სანდო, საჯარო, გასაღების გარეშე ხელმისაწვდომ სამეცნიერო/ოფიციალურ კატალოგს და მომხმარებელს რეალურ, დამოწმებად

შედეგებს სთავაზობს ასარჩევად. ეს ძებნა არა მხოლოდ მოთხოვნის ფორმიდანაა ხელმისაწვდომი, არამედ სისტემა მას ავტომატურადაც სთავაზობს მომხმარებელს, როცა არჩეულ მონაცემებში დროითი ხარვეზები აღმოჩნდება (FR-26).

პრინციპი: არაფერი გამოგონილი

დიდი ენობრივი მოდელი (LLM) აქ არ გამოიყენება წყაროს მოსაძებნად ან URL-ის ან citation-ის შესათხზად – ეს საფრთხეს შეუქმნიდა მონაცემის სანდოობას. ძებნა ხდება მხოლოდ ორი კონკრეტული, სანდო API-ის მეშვეობით; დაბრუნებული ყოველი ველი (სათაური, ორგანიზაცია, ბმული) პირდაპირ წამოღებულია იმ API-ის საკუთარი პასუხიდან.

7.1 ორი წყარო-კატალოგი

- WHO Global Health Observatory (GHO) API – ჯანმო-ს საკუთარი, ოფიციალური OData API (`ghoapi.azureedge.net`). დაავადების საკვანძო სიტყვით (მაგ. „Malaria") ძებნა აბრუნებს ათეულობით რეალურ ინდიკატორს („დადასტურებული შემთხვევები", „შეფასებული შემთხვევები", „სიკვდილიანობა" და ა.შ.) – მომხმარებელი თავად ირჩევს რომელი ზუსტად ჰინტერესებს, ერთადერთი ჩაშენებული ინდიკატორის ნაცვლად.

- HDX – Humanitarian Data Exchange (`data.humdata.org`) – გაერო-ს (UN OCHA) კატალოგი, სადაც სამთავრობო/ჯანმო-ს/არასამთავრობო ორგანიზაციები პირდაპირ ატვირთავენ ჩამოსატვირთ CSV/XLSX ფაილებს. გამოსადეგია მაშინ, როცა WHO GHO-ს არ აქვს საკმარისად დეტალური (მაგ. თვიური) მონაცემი კონკრეტული დაავადებისთვის.

7.2 როგორ ჯდება არსებულ არქიტექტურაში

მთავარი დიზაინის გადაწყვეტილება: HDX-დან ნაპოვნი შედეგი არ საჭიროებს ახალ parser-ს – ის უბრალოდ გადის უკვე არსებული და დატესტილი `custom_url` channel-ით (`get_case_data_from_url`), რადგან HDX პირდაპირ ჩამოსატვირთ ცხრილოვან ფაილებს გვთავაზობს. მხოლოდ WHO GHO-სთვის დაემატა ახალი, სპეციალური ადაპტერი (`services/who_gho.py`), რადგან მისი მონაცემები ცხრილის ნაცვლად სტრუქტურირებული API-დანაა წამოსაღები.

WHO GHO-ს ინდიკატორები ყოველთვის წლიურია, მაშინაც კი, როცა თავად დაავადებას (მაგ. დენგე OpenDengue-ს მეშვეობით) თვიური მონაცემი აქვს. ETL პროცესი (`run_integration`) ამ შემთხვევაში მიმართვის გარჩევადობას (`resolution`) დაავადების ნაგულისხმევი მნიშვნელობის ნაცვლად რეალურად გამოძახებული წყაროდან იღებს – წინააღმდეგ შემთხვევაში დაავადების და კლიმატის სერიები არასწორ, შეუთავსებელ პერიოდებზე შეიძლებოდა გაერთიანებულიყო.

არჩეული წყაროს citation ავტომატურად ჩნდება საბოლოო შედეგის „Sources" სექციაში, ისე რომ მომხმარებელს ყოველთვის ზუსტად ეცოდინება საიდან მოვიდა თითოეული რიცხვი.

7.3 შეზღუდვები

- ძებნა შემოიფარგლება მხოლოდ ამ ორი კატალოგით – ეს შეგნებული არჩევანია (ვიწრო, სანდო allowlist ღია web-ძებნის ნაცვლად), მაგრამ ნიშნავს, რომ ამ ორ წყაროში არარსებული მონაცემი უბრალოდ არ გამოჩნდება;

- WHO GHO-ს ინდიკატორები თითქმის ყოველთვის წლიურია – უფრო დეტალური (თვიური) ანალიზისთვის HDX ან საკუთარი URL/ფაილი რჩება სჯობს არჩევანად;

- ორივე API საჯარო და უფასოა, მაგრამ გარე სერვისებია – დროებითი მიუწვდომლობის შემთხვევაში ძებნა უბრალოდ ცარიელ სიას აბრუნებს (არა შეცდომას), და მომხმარებელს კვლავ შეუძლია custom URL/ატვირთვა.

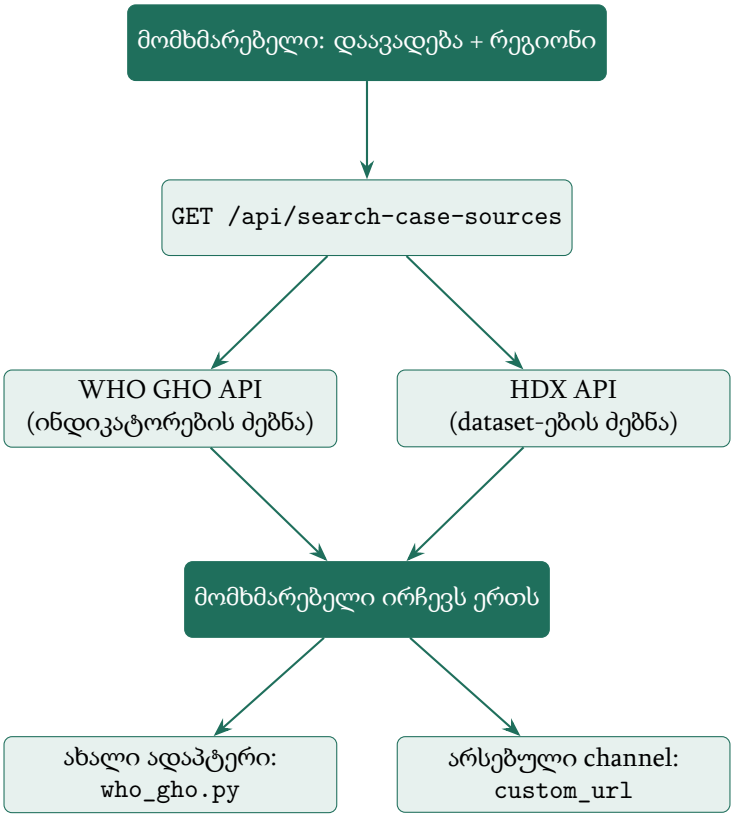


Figure 3: წყაროების ცოცხალი ძებნის ნაკადი

8 მონაცემთა ინტელექტუალური ჰარმონიზაცია და გამჭვირვალობის ჟურნალი

სამეცნიერო და ჰუმანიტარულ მონაცემთა ბაზებში (მაგ. HDX, კვლევითი ცენტრების CSV ფაილები) სვეტების სახელები და ფორმატები ხშირად არასტანდარტულია (მაგ. `period`, `observation_date`, `malaria_cases`, `incidence_rate`).

პლატფორმაში დაინერგა AI Data Harmonizer & Audit System:

- სვეტების მოქნილი ამოცნობა და Fuzzy Matching: სისტემა ავტომატურად აიდენტიფიცირებს დროითი ინდექსის სვეტს და დაავადების შემთხვევების მეტრიკას, მაშინაც კი თუ მათი დასახელებები განსხვავდება;
- მონაცემთა გაწმენდა და ფორმატირება: არასწორი ან ცარიელი ჩანაწერების გაფილტვრა რეალური მონაცემების დაუმახინჯებლად;
- გამჭვირვალობის ჟურნალი (Data Transformation Audit Log): პროგრამა აღრიცხავს ყველა ცვლილებას – რა სვეტები მიიღო, რა გარდაქმნა, რამდენი სტრიქონი გაიფილტრა და რა დარჩა;
- AI-ს მიერ გენერირებული ადამიანური ახსნა: Gemini LLM მომხმარებელს მარტივ ენაზე უხსნის მონაცემთა დამუშავების მთლიან პროცესს, რაც თავიდან არიდებს გაუგებრობებსა და მონაცემთა არასწორ ინტერპრეტაციას.

9 მრავალგანზომილებიანი ინტერაქტიული ვიზუალიზაცია და KPI მეტრიკები

კლიმატისა და ეპიდემიოლოგიური მონაცემების სიღრმისეული ანალიზისთვის ინტერფეისს დაემატა მართვადი ვიზუალიზაციის კომპონენტები:

- სწრაფი მეტრიკების ბარათები (Summary KPIs): ცხრილისა და გრაფიკის თავზე გამოისახება 4 საკვანძო ინდიკატორი – ჯამური შემთხვევები, საშუალო ტემპერატურა (მინ/მაქს დიაპაზონით), ჯამური/საშუალო ნალექი და პიკური აფეთქების პერიოდი შემთხვევების რიცხვით;
- ინტერაქტიული გრაფიკის ჩამრთველები (Dynamic Series Toggles): მომხმარებელს შეუძლია ჩამრთველი ღილაკებით (FilterChips) რეალურ დროში ჩართოს ან გამორთოს სასურველი მრუდები (შემთხვევები, ტემპერატურა, ნალექი);
- ორღერძიანი ადაპტური მასშტაბირება: გრაფიკი დინამიურად ირჩევს საბაზისო ღერძს არჩეული მეტრიკების მიხედვით, რაც უზრუნველყოფს მკაფიო აღქმადობას მაშინაც კი, როცა მხოლოდ ნალექი ან მხოლოდ ტემპერატურაა არჩეული.

10 ამჟამად განხორციელებული ფუნქციები

- სტრუქტურირებული ფორმა (დაავადება, რეგიონი, ცვლადები, პერიოდი, წყარო), პლუს არასავალდებულო ბუნებრივი ენით მოთხოვნის აღწერა, რომელსაც LLM ფორმის წინასწარი შევსების სახით ამუშავებს (იხ. §4);
- 39 რეგიონი რეალური, თვიური სიხშირის დენგეს მონაცემებით;
- დაყოვნებული კლიმატური ცვლადების (Lags 1–6) გენერაცია ცალკეულ სვეტებად და კლიმატის მონაცემების Lag-ბუფერით ამოღება საწყისი რიგების დანაკარგის გარეშე (FR-23);
- წარმომავლობის მეტამონაცემები (წყაროები, ლიცენზიები, ნაბიჯები, ვერსია, დრო) ყველა CSV/JSON ექსპორტსა და PDF-ში (FR-25);
- მონაცემთა სისრულისა და დროითი ხარვეზების დეტერმინისტული ამოცნობა, მიზეზის განმარტება და ალტერნატიული წყაროების ავტომატური შეთავაზება (FR-26);
- ორი მონაცემთა წყაროს ემპირიული შედარება თანხვედრ პერიოდში (r, MAD, საშუალო სხვაობა) სეზონური ციკლისა და ეპიდზედამხედველობის შენიშვნებითა და Sparkline-ვიზუალიზაციით (FR-27);
- სამი ალტერნატიული სამეცნიერო/ოფიციალური კლიმატის წყარო (Open-Meteo, NASA POWER, TMD – ბოლო მხოლოდ ტაილანდისთვის);
- დაავადების მონაცემთა წყაროების ცოცხალი ძებნა WHO GHO-სა და HDX-ში, ერთი ჩაშენებული წყაროს ნაცვლად (იხ. §7);
- AI-ზე დაფუძნებული მონაცემთა ჰარმონიზაცია, სვეტების მოქნილი ამოცნობა და გამჭვირვალე Audit Log ინტერაქტიული მოდალური ფანჯრით (იხ. §8);
- მრავალმრუდიანი ინტერაქტიული გრაფიკი ჩამრთველებით (შემთხვევები, ტემპერატურა, ნალექი) და KPI ინდიკატორების ბარათები (იხ. §9);
- მომხმარებლის მიერ მითითებული URL ან ატვირთული ფაილი, როგორც დამატებითი მონაცემთა წყარო;
- რეგიონის არჩევა ინტერაქტიული 2D რუკით, სადაც თითოეულ მხარდაჭერილ რეგიონს მარკერი აქვს ზუსტ საცნობარო კოორდინატზე;
- ყოველი ნაბიჯის ტექსტური ჩვენება მომხმარებელს, და გამჭვირვალობა იმის შესახებ, ახსნა ნამდვილად LLM-მა გენერირა თუ fallback ტექსტია;
- ცნობილი, მოსალოდნელი backend შეცდომების (მაგ. TMD-ის კონფიგურაციის ან custom წყაროს ფორმატის პრობლემა) მკაფიო 502 პასუხად დაბრუნება ბუნდოვანი 500-ის ნაცვლად;

- შედეგის კეშირება last_verified დროის ნიშნულით;
- Gemini API-ს გამოძახებების სიხშირის შეზღუდვა (rate limiting);
- მიღებული მონაცემების გადმოწერა CSV/JSON ფორმატში და სრული PDF ანგარიში;
- ერთი Docker კონტეინერი, რომელშიც Backend ემსახურება frontend-საც – მარტივი განთავსებისთვის.

11 შემდეგი ნაბიჯები

- მონაცემთა ხარვეზების შევსება სხვა წყაროდან მხოლოდ მომხმარებლის ექსპლიციტური გადამოწმებისა და დადასტურების შემდეგ, თითოეულ სტრიქონზე წყაროს აღმნიშვნელი სვეტით (`case_source`), რათა თავიდან ავიცილოთ განსხვავებული ეპიდემიოლოგიური განსაზღვრებების გაუცნობიერებელი შერევა (A20);
- TMD-ის რეალურ API პასუხზე smoke-ტესტი და, საჭიროებისამებრ, `_parse_tmd_response`-ის ველების დაზუსტება, როგორც კი წვდომის მონაცემები დარეგისტრირდება;
- მომავალი კლიმატის პროგნოზების (CMIP6/CORDEX) და bias correction-ის ინტეგრაცია ემისიის სცენარების მხარდასაჭერად;
- გრიდირებული (რეგიონის მთელ ტერიტორიაზე გავრცობილი) მონაცემები ერთი წარმომადგენლობით წერტილის ნაცვლად;
- ნამდვილი ფონური დამუშავების რიგი (job queue) გრძელვადიანი მოთხოვნებისთვის;
- დაავადების მოდელების პირდაპირი მიბმა გამომავალ მონაცემებზე.