

LLM-Climate-Health

ტექნიკური დოკუმენტაცია და ლექსიკონი

LLM-ზე დაფუძნებული ETL პლატფორმა კლიმატისა და
ჯანმრთელობის მონაცემთა ინტეგრაციისთვის

საბაკალავრო ნაშრომი

ბრემენის უნივერსიტეტი – ინფორმატიკის ფაკულტეტი

ავტორი: სერგი კონიაშვილი

თარიღი: August 20, 2026

ეს დოკუმენტი აღწერს პლატფორმის არქიტექტურას, მონაცემთა
ინტეგრაციის პროცესს და მასში გამოყენებულ ძირითად ცნებებს –
საბაკალავრო ნაშრომში გამოსაყენებლად.

Contents

1	შესავალი	2
2	სისტემის არქიტექტურა	2
2.1	Backend-ის მოდულები	2
3	მონაცემთა ინტეგრაციის პროცესი (ETL)	3
3.1	გამჭვირვალობა და კეშირება	3
4	ბუნებრივი ენით მოთხოვნის ინტერპრეტაცია	4
4.1	დახურული ლექსიკონი გამოწვდომის თავიდან ასაცილებლად	4
5	საკვანძო ცნებები კლიმატურ მონაცემებში	4
5.1	რეანალიზი (Reanalysis)	4
5.2	რეანალიზი vs. მოდელის პროგნოზი (Projection)	4
5.3	Bias Correction (მიკერძოების კორექცია)	4
5.4	ემისიის სცენარები (Emission Scenarios)	5
5.5	სივრცული და დროითი შეთანხმება (Join)	5
6	გამოყენებული მონაცემთა წყაროები	5
6.1	რეგიონულად შეზღუდული წყარო: TMD	5
7	დაავადების მონაცემთა წყაროების ცოცხალი ძეგლი	6
7.1	ორი წყარო-კატალოგი	6
7.2	როგორ ჯდება არსებულ არქიტექტურაში	6
7.3	შეზღუდვები	6
8	ამჟამად განხორციელებული ფუნქციები	7
9	შემდეგი ნაბიჯები	8

1 შესავალი

ბევრი დაავადება კლიმატზეა დამოკიდებული – მათი გადამტანები (მაგალითად, კოლოები) მგრძნობიარენი არიან ტემპერატურის, ნალექისა და ტენიანობის მიმართ. ეს ნიშნავს, რომ კლიმატური მონაცემები შეიძლება გამოყენებულ იქნას როგორც ადრეული ინდიკატორი დაავადების აფეთქების რისკისთვის.

ამ პროექტის მიზანია შეიქმნას ზოგადი დანიშნულების პლატფორმა, რომელიც საშუალებას მისცემს მომხმარებელს – პროგრამირების ან კლიმატოლოგიის ცოდნის გარეშე – ბუნებრივი ენით ჩამოაყალიბოს მოთხოვნა (დაავადება, რეგიონი, კლიმატური ცვლადები) და მიიღოს ანალიზისთვის მზა, ურთიერთდაკავშირებული მონაცემები. დიდი ენობრივი მოდელი (LLM) ამ მოთხოვნას გარდაქმნის შესრულებად ინტეგრაციის გეგმად და ყოველ ნაბიჯს მარტივი ენით უხსნის მომხმარებელს.

მნიშვნელოვანია: პლატფორმა აწარმოებს მონაცემებს, არა პროგნოზებს. შედეგი გამოიყენება როგორც შემავალი მონაცემები შემდგომი დაავადების მოდელისთვის.

ვალიდაციის სცენარი

პროექტი ვალიდირებულია დენგეს ცხელების მაგალითზე ტაილანდში, თუმცა არქიტექტურა შექმნილია ისე, რომ იგივე ლოგიკა ვრცელდებოდეს სხვა ვექტორგადამტან დაავადებებზეც (მაღარია, ქოლერა, ლაიმის დაავადება) და ნებისმიერ რეგიონზე, სადაც არსებობს საკმარისი მონაცემები.

2 სისტემის არქიტექტურა

პლატფორმა აგებულია სამი ფენისგან: frontend (Flutter), backend (Python/FastAPI) და გარე მონაცემთა წყაროები. Flutter არჩეულია იმიტომ, რომ ერთი კოდით შესაძლებელია აპლიკაციის აგება ვებ-ბრაუზერის, მობილურისთვის და დესკტოპისთვისაც – ეს მნიშვნელოვანია, რადგან პლატფორმა გამოიხატავს ფართო ხელმისაწვდომობისთვის ბმულის საშუალებით.




Figure 1: პლატფორმის მაღალი დონის არქიტექტურა

2.1 Backend-ის მოდულები

- config – გარემოს ცვლადები, მხარდაჭერილი რეგიონების/წყაროების რეესტრი;

- services/dengue – დაავადების შემთხვევების მონაცემები (OpenDengue, URL, ატვირთვა);
- services/climate – კლიმატური რეანალიზის მონაცემები (Open-Meteo, NASA POWER);
- services/etl – ორკესტრაცია: მოძიება, აგრეგირება, დაკავშირება;
- services/llm – Gemini API-სთან კომუნიკაცია, rate-limiting;
- services/cache – შედეგების დროებითი შენახვა და last_verified დროის ნიშნულის დამატება.

3 მონაცემთა ინტეგრაციის პროცესი (ETL)

ყოველი მოთხოვნა გადის შემდეგ ეტაპებს, რომლებიც მომხმარებელს ჩანს ეკრანზე – ეს იმისთვისაა, რომ მომხმარებელმა დარწმუნებით იცოდეს, რომ მისი ბრძანება სწორად შესრულდა.




Figure 2: ETL პროცესის ეტაპები (ერთი მოთხოვნისთვის)

3.1 გამჭვირვალობა და კეშირება

თითოეული ნაბიჯი ტექსტურად ფორმდება და უბრუნდება frontend-ს, ისე რომ მომხმარებელს შეუძლია ნახოს ზუსტად რა მოხდა. თუ იგივე მოთხოვნა მეორდება 15 წუთის განმავლობაში, სისტემა უბრუნებს კეშირებულ შედეგს (გარე API-ების ზედმეტი დატვირთვის თავიდან ასაცილებლად) და უჩვენებს ბოლო გადამოწმების დროის ნიშნულს (last_verified), რომ მომხმარებელმა იცოდეს რამდენად ახალია მონაცემი.

ახსნის ტექსტი (explanation) ყოველთვის Gemini-ს მეშვეობით გენერირდება, მაგრამ თუ API-ის გამოძახება ჩავარდება (მაგ. rate limit ან დროებითი მიუწვდომლობა), სისტემა წინასწარ მომზადებულ, ზოგად ტექსტს აბრუნებს ისე, რომ მომხმარებელმა საერთოდ არაფერი არ დაინახოს ცარიელი ადგილის ნაცვლად. რომ ეს ჩანაცვლება არასდროს გავიდეს ნამდვილ, კონკრეტულ მოთხოვნაზე მორგებულ ტექსტად, პასუხს დაემატა ცალკე ველი explanation_source ("llm" ან "fallback") – frontend პირდაპირ აჩვენებს, რომელი შემთხვევა მოხდა.

4 ბუნებრივი ენით მოთხოვნის ინტერპრეტაცია

თავდაპირველად მომხმარებელი მოთხოვნას მხოლოდ სტრუქტურირებული ფორმის (dropdown-ების და თარიღის ველების) მეშვეობით ავსებდა. ამას დაემატა დამატებითი, არასავალდებულო გზა: მომხმარებელს შეუძლია მოთხოვნა თავისუფალი ტექსტით აღწეროს (მაგ. „დენგე ტაილანდში 2015-დან 2023 წლამდე, ყოველთვიურად, ტემპერატურა და ნალექი“), და Gemini LLM ცდილობს ამის საფუძველზე ფორმის ველების ავტომატურად შევსებას (POST /api/parse-request).

უსაფრთხოების პრინციპი: მხოლოდ შევსება, არასდროს გაშვება

ბუნებრივი ენის პარსინგი მხოლოდ წინასწარ ავსებს ფორმას – ის არასდროს უშვებს ETL პროცესს პირდაპირ. მომხმარებელს ყოველთვის შეუძლია შევსებული ველების გადამოწმება და საჭიროების შემთხვევაში ხელით შესწორება, სანამ „Run integration“-ზე დააჭერს. ეს ინარჩუნებს პლატფორმის ძირითად პრინციპს: LLM ხსნის და ეხმარება, მაგრამ არასდროს იღებს გადაწყვეტილებას მომხმარებლის ნაცვლად.

4.1 დახურული ლექსიკონი გამონაგონის თავიდან ასაცილებლად

LLM-ს არ აქვს თავისუფლება ნებისმიერი მნიშვნელობის შემოთავაზების – prompt-ში პირდაპირ ეწერება ყველა დაშვებული დაავადება, რეგიონი, ცვლადი, აგრეგაცია და კლიმატის წყარო, და მოდელს მოეთხოვება აირჩიოს მხოლოდ ამ სიებიდან, ან დატოვოს ველი ცარიელი (null), თუ ტექსტში ცალსახად არ ჩანს. პასუხის დამუშავებისას (_coerce_parsed_json) ყოველი მნიშვნელობა ხელახლა მოწმდება backend-ის კოდში – თუ მოდელმა მაინც შემოგვთავაზა ამ სიების გარეთა მნიშვნელობა, ის იშლება (None-ად იქცევა) და ეს ფაქტი მომხმარებელს უჩნდება „notes“ ველში ახსნილი დაშვების სახით. ამგვარად, არასწორად ამოცნობილი დაავადება ან რეგიონი ვერასდროს მიაღწევს პირდაპირ ETL პროცესამდე.

5 საკვანძო ცნებები კლიმატურ მონაცემებში

ეს თავი გამოსადეგია, როგორც მოკლე სასწავლო მასალა – განმარტავს ტერმინებს, რომლებსაც პლატფორმა იყენებს.

5.1 რეანალიზი (Reanalysis)

რეანალიზი არის წარსული ამინდის მონაცემების მეცნიერულად აღდგენილი, თანმიმდევრული სურათი. ის იქმნება ისტორიული დაკვირვებების (მეტეოსადგურები, თანამგზავრები, ხომალდები) და ფიზიკური ამინდის მოდელის შერწყმით. ეს არ არის ერთი კონკრეტული სადგურის ნედლი მონაცემი – ის წარმოადგენს საუკეთესო შეფასებას იმისა, თუ როგორი იყო ატმოსფერო კონკრეტულ ადგილას და დროს. პლატფორმა იყენებს ECMWF ERA5 რეანალიზს (Open-Meteo-ს საშუალებით) და NASA POWER-ს (MERRA-2 რეანალიზზე დაფუძნებული).

5.2 რეანალიზი vs. მოდელის პროგნოზი (Projection)

რეანალიზი აღწერს წარსულს და კორექტირდება რეალურ დაკვირვებებზე. მოდელის პროგნოზი (მაგ. CMIP6/CORDEX სცენარები) კი სიმულირებს მომავალ კლიმატს ემისიების სხვადასხვა დაშვებით და არ არის დაკავშირებული კონკრეტულ დაკვირვებულ მოვლენებთან. ამჟამინდელი იმპლემენტაცია იყენებს მხოლოდ ისტორიულ რეანალიზს (scenario=historical); მომავალი პროგნოზების ინტეგრაცია დაგეგმილია შემდეგ ეტაპზე.

5.3 Bias Correction (მიკერძოების კორექცია)

კლიმატის მოდელს ხშირად აქვთ სისტემატური გადახრა რეალობისგან (მაგალითად, მუდმივად აჭარბებენ ნალექის რაოდენობას კონკრეტულ რეგიონში). Bias correction არის სტატისტიკური

მეთოდი, რომელიც ასწორებს ამ გადახრას ისტორიულ დაკვირვებებთან შედარებით, სანამ მონაცემი გამოყენებული იქნება შემდგომი ანალიზისთვის. ეს განსაკუთრებით მნიშვნელოვანია მაშინ, როცა პროგნოზული (არა-რეანალიზის) მონაცემები გამოიყენება.

5.4 ემისიის სცენარები (Emission Scenarios)

ეს არის დაშვებები მომავალი სათბურის გაზების გამონაბოლქვის შესახებ (მაგ. SSP1-2.6 – დაბალი ემისია, SSP5-8.5 – მაღალი ემისია), რომლებზეც დაფუძნებულია კლიმატის მომავალი პროგნოზები. რადგან მომავალი ზუსტად უცნობია, მეცნიერები იყენებენ რამდენიმე სცენარს პარალელურად.

5.5 სივრცული და დროითი შეთანხმება (Join)

სხვადასხვა წყაროს მონაცემები განსხვავებული სივრცული (წერტილი, ზადე, რეგიონი) და დროითი (დღიური, თვიური, წლიური) გარჩევადობით მოდის. პლატფორმა კლიმატურ მონაცემებს დღიურიდან თვიურამდე აგრეგირებს (ტემპერატურა – საშუალო, ნალექი – ჯამი), რათა ის დაემთხვეს დაავადების შემთხვევების ჩვეულებრივ თვიურ ანგარიშგებას, შემდეგ კი აერთიანებს ორივეს საერთო თვე-წლის გასაღებით.

6 გამოყენებული მონაცემთა წყაროები

- OpenDengue – აკადემიური, საჯაროდ ხელმისაწვდომი დენგეს შემთხვევების არქივი (Clarke et al., 2024, Scientific Data). მოიცავს 39 ქვეყანას საკმარისი (12+ თვე) თვიური გარჩევადობით.
- Open-Meteo Historical Archive – ECMWF ERA5 რეანალიზზე დაფუძნებული, უფასო, გასაღების გარეშე ხელმისაწვდომი API.
- NASA POWER – ალტერნატიული სამეცნიერო კლიმატური წყარო (MERRA-2 რეანალიზი), ასევე გასაღების გარეშე ხელმისაწვდომი.
- Thai Meteorological Department (TMD) – ტაილანდის ეროვნული, ოფიციალური მეტეოროლოგიური სამსახურის API (`data.tmd.go.th`), ხელმისაწვდომი მხოლოდ ტაილანდისთვის (იხ. ქვემოთ).
- მომხმარებლის საკუთარი წყარო – URL ან ატვირთული CSV ფაილი, თუ მომხმარებელს სურს საკუთარი სამეცნიერო მონაცემების გამოყენება.

6.1 რეგიონულად შეზღუდული წყარო: TMD

ღია, გლობალური კლიმატის წყაროებისგან (Open-Meteo, NASA POWER) განსხვავებით, TMD მხოლოდ ტაილანდის ტერიტორიაზეა ხელმისაწვდომი და მოითხოვს რეგისტრაციას (`uid/ukey` წყვილი, უფასო, `data.tmd.go.th`-ზე). ეს შეზღუდვა კოდში ცალკე რეესტრშია აღწერილი (`CLIMATE_SOURCE_REGIONS`), რომელსაც backend ამოწმებს მოთხოვნის დროს – თუ მომხმარებელი TMD-ს სხვა რეგიონისთვის აირჩევს, მკაფიო 400 შეცდომას იღებს დაბნეული ან ცარიელი პასუხის ნაცვლად.

გულწრფელი შეზღუდვა: დაუდასტურებელი პასუხის სტრუქტურა

TMD-ს საჯარო დოკუმენტაცია აღწერს endpoint-ებს და საჭირო `uid/ukey` პარამეტრებს, მაგრამ არ აქვეყნებს ზუსტ JSON ველების სახელებს. შესაბამისად, პასუხის დამუშავების ლოგიკა (`_parse_tmd_response`) დაწერილია დოკუმენტაციაში აღწერილი ველების საფუძველზე და საჭიროებს რეალურ `smoke`-ტესტს, როგორც კი წვდომის მონაცემები (`TMD_API_UID/TMD_API_UKEY`) დარეგისტრირდება. ეს გაურკვევლობა შეგნებულად არის იზოლირებული ერთ ფუნქციაში, რომ საჭიროების შემთხვევაში გასწორება ერთ ადგილას შემოიფარგლოს.

7 დაავადების მონაცემთა წყაროების ცოცხალი ძეგნი

თავდაპირველ ვერსიაში თითო დაავადებას მხოლოდ ერთი, კოდში ჩაშენებული წყარო ჰქონდა მიბმული – მომხმარებელს არჩევანის საშუალება არ ჰქონდა. ამის გამოსასწორებლად დაემატა ცოცხალი ძეგნის ფუნქცია: backend-ი რეალურ დროში ეკითხება ორ სანდო, საჯარო, გასაღების გარეშე ხელმისაწვდომ სამეცნიერო/ოფიციალურ კატალოგს და მომხმარებელს რეალურ, დამოწმებად შედეგებს სთავაზობს ასარჩევად.

პრინციპი: არაფერი გამოგონილი

დიდი ენობრივი მოდელი (LLM) აქ არ გამოიყენება წყაროს მოსაძებნად ან URL-ის ან citation-ის შესათხზად – ეს საფრთხეს შეუქმნიდა მონაცემის სანდოობას. ძეგნი ხდება მხოლოდ ორი კონკრეტული, სანდო API-ის მეშვეობით; დაბრუნებული ყოველი ველი (სათაური, ორგანიზაცია, ბმული) პირდაპირ წამოღებულია იმ API-ის საკუთარი პასუხიდან.

7.1 ორი წყარო-კატალოგი

- WHO Global Health Observatory (GHO) API – ჯანმო-ს საკუთარი, ოფიციალური OData API (ghoapi.azureedge.net). დაავადების საკვანძო სიტყვით (მაგ. „Malaria”) ძეგნი აბრუნებს ათეულობით რეალურ ინდიკატორს („დადასტურებული შემთხვევები”, „შეფასებული შემთხვევები”, „სიკვდილიანობა” და ა.შ.) – მომხმარებელი თავად ირჩევს რომელი ზუსტად ჰინტერესებს, ერთადერთი ჩაშენებული ინდიკატორის ნაცვლად.
- HDX – Humanitarian Data Exchange (data.humdata.org) – გაერო-ს (UN OCHA) კატალოგი, სადაც სამთავრობო/ჯანმო-ს/არასამთავრობო ორგანიზაციები პირდაპირ ატვირთავენ ჩამოსატვირთ CSV/XLSX ფაილებს. გამოსადეგია მაშინ, როცა WHO GHO-ს არ აქვს საკმარისად დეტალური (მაგ. თვიური) მონაცემი კონკრეტული დაავადებისთვის.

7.2 როგორ ჯდება არსებულ არქიტექტურაში

მთავარი დიზაინის გადაწყვეტილება: HDX-დან ნაპოვნი შედეგი არ საჭიროებს ახალ parser-ს – ის უბრალოდ გადის უკვე არსებული და დატესტილი custom_url channel-ით (`get_case_data_from_url`), რადგან HDX პირდაპირ ჩამოსატვირთ ცხრილოვან ფაილებს გვთავაზობს. მხოლოდ WHO GHO-სთვის დაემატა ახალი, სპეციალური ადაპტერი (services/who_gho.py), რადგან მისი მონაცემები ცხრილის ნაცვლად სტრუქტურირებული API-დანაა წამოსაღები.

WHO GHO-ს ინდიკატორები ყოველთვის წლიურია, მაშინაც კი, როცა თავად დაავადებას (მაგ. დენგე OpenDengue-ს მეშვეობით) თვიური მონაცემი აქვს. ETL პროცესი (`run_integration`) ამ შემთხვევაში მიმართვის გარჩევადობას (`resolution`) დაავადების ნაგულისხმევი მნიშვნელობის ნაცვლად რეალურად გამოძახებული წყაროდან იღებს – წინააღმდეგ შემთხვევაში დაავადების და კლიმატის სერიები არასწორ, შეუთავსებელ პერიოდებზე შეიძლება გაერთიანებულიყო.

არჩეული წყაროს citation ავტომატურად ჩნდება საბოლოო შედეგის „Sources” სექციაში, ისე რომ მომხმარებელს ყოველთვის ზუსტად ეცოდინება საიდან მოვიდა თითოეული რიცხვი.

7.3 შეზღუდვები

- ძეგნი შემოიფარგლება მხოლოდ ამ ორი კატალოგით – ეს შეგნებული არჩევანია (ვიწრო, სანდო allowlist ღია web-ძეგნის ნაცვლად), მაგრამ ნიშნავს, რომ ამ ორ წყაროში არარსებული მონაცემი უბრალოდ არ გამოჩნდება;
- WHO GHO-ს ინდიკატორები თითქმის ყოველთვის წლიურია – უფრო დეტალური (თვიური) ანალიზისთვის HDX ან საკუთარი URL/ფაილი რჩება სჯობს არჩევანად;




Figure 3: წყაროების ცოცხალი ძეგნის ნაკადი

- ორივე API საჯარო და უფასოა, მაგრამ გარე სერვისებია – დროებითი მიუწვდომლობის შემთხვევაში ძეგნა უბრალოდ ცარიელ სიას აბრუნებს (არა შეცდომას), და მომხმარებელს კვლავ შეუძლია custom URL/ატვირთვა.

8 ამჟამად განხორციელებული ფუნქციები

- სტრუქტურირებული ფორმა (დაავადება, რეგიონი, ცვლადები, პერიოდი, წყარო), პლუს არასავალდებულო ბუნებრივი ენით მოთხოვნის აღწერა, რომელსაც LLM ფორმის წინასწარი შევსების სახით ამუშავებს (იხ. §4);
- 39 რეგიონი რეალური, თვითონ სიხშირის დენგეს მონაცემებით;
- სამი ალტერნატიული სამეცნიერო/ოფიციალური კლიმატის წყარო (Open-Meteo, NASA POWER, TMD – ბოლო მხოლოდ ტაილანდისთვის);
- დაავადების მონაცემთა წყაროების ცოცხალი ძეგნა WHO GHO-სა და HDX-ში, ერთი ჩაშენებული წყაროს ნაცვლად (იხ. §7);
- მომხმარებლის მიერ მითითებული URL ან ატვირთული ფაილი, როგორც დამატებითი მონაცემთა წყარო;
- რეგიონის არჩევა 2D რუკით ან, სურვილისამებრ, ინტერაქტიული 3D გლობუსით (ზოგ ბრაუზერში 3D რენდერი შეიძლება ცარიელი გამოჩნდეს – ასეთ შემთხვევაში 2D რუკა ყოველთვის ხელმისაწვდომია);
- ყოველი ნაბიჯის ტექსტური ჩვენება მომხმარებელს, და გამჭვირვალობა იმის შესახებ, ახსნა ნამდვილად LLM-მა გენერირა თუ fallback ტექსტია;

- ცნობილი, მოსალოდნელი backend შეცდომების (მაგ. TMD-ის კონფიგურაციის ან custom წყაროს ფორმატის პრობლემა) მკაფიო 502 პასუხად დაბრუნება ბუნდოვანი 500-ის ნაცვლად;
- შედეგის კეშირება last_verified დროის ნიშნულით;
- Gemini API-ს გამოძახებების სიხშირის შეზღუდვა (rate limiting);
- მიღებული მონაცემების გადმოწერა CSV/JSON ფორმატში;
- ერთი Docker კონტეინერი, რომელშიც Backend ემსახურება frontend-საც – მარტივი განთავსებისთვის.

9 შემდეგი ნაბიჯები

- TMD-ის რეალურ API პასუხზე smoke-ტესტი და, საჭიროებისამებრ, _parse_tmd_response-ის ველების დაზუსტება, როგორც კი წვდომის მონაცემები დარეგისტრირდება;
- მომავალი კლიმატის პროგნოზების (CMIP6/CORDEX) და bias correction-ის ინტეგრაცია ემისიის სცენარების მხარდასაჭერად;
- გრიდირებული (რეგიონის მთელ ტერიტორიაზე გავრცობილი) მონაცემები ერთი წარმომადგენლობითი წერტილის ნაცვლად;
- ნამდვილი ფონური დამუშავების რიგი (job queue) გრძელვადიანი მოთხოვნებისთვის;
- დაავადების მოდელების პირდაპირი მიბმა გამომავალ მონაცემებზე.