

LLM-Climate-Health

ტექნიკური დოკუმენტაცია და ლექსიკონი

LLM-ზე დაფუძნებული ETL პლატფორმა კლიმატისა და
ჯანმრთელობის მონაცემთა ინტეგრაციისთვის

საბაკალავრო ნაშრომი

ბრემენის უნივერსიტეტი – ინფორმატიკის ფაკულტეტი

ავტორი: სერგი კონიაშვილი

თარიღი: August 6, 2026

ეს დოკუმენტი აღწერს პლატფორმის არქიტექტურას, მონაცემთა
ინტეგრაციის პროცესს და მასში გამოყენებულ ძირითად ცნებებს –
საბაკალავრო ნაშრომში გამოსაყენებლად.

Contents

1 შესავალი	2
2 სისტემის არქიტექტურა	2
2.1 Backend-ის მოდულები	2
3 მონაცემთა ინტეგრაციის პროცესი (ETL)	3
3.1 გამჭვირვალობა და კეშირება	3
4 საკვანძო ცნებები კლიმატურ მონაცემებში	3
4.1 რეანალიზი (Reanalysis)	3
4.2 რეანალიზი vs. მოდელის პროგნოზი (Projection)	4
4.3 Bias Correction (მიკერძოების კორექცია)	4
4.4 ემისიის სცენარები (Emission Scenarios)	4
4.5 სივრცული და დროითი შეთანხმება (Join)	4
5 გამოყენებული მონაცემთა წყაროები	4
6 ამჟამად განხორციელებული ფუნქციები	4
7 შემდეგი ნაბიჯები	5

1 შესავალი

ბევრი დაავადება კლიმატზეა დამოკიდებული – მათი გადამტანები (მაგალითად, კოლოები) მგრძნობიარენი არიან ტემპერატურის, ნალექისა და ტენიანობის მიმართ. ეს ნიშნავს, რომ კლიმატური მონაცემები შეიძლება გამოყენებულ იქნას როგორც ადრეული ინდიკატორი დაავადების აფეთქების რისკისთვის.

ამ პროექტის მიზანია შეიქმნას ზოგადი დანიშნულების პლატფორმა, რომელიც საშუალებას მისცემს მომხმარებელს – პროგრამირების ან კლიმატოლოგიის ცოდნის გარეშე – ბუნებრივი ენით ჩამოაყალიბოს მოთხოვნა (დაავადება, რეგიონი, კლიმატური ცვლადები) და მიიღოს ანალიზისთვის მზა, ურთიერთდაკავშირებული მონაცემები. დიდი ენობრივი მოდელი (LLM) ამ მოთხოვნას გარდაქმნის შესრულებად ინტეგრაციის გეგმად და ყოველ ნაბიჯს მარტივი ენით უხსნის მომხმარებელს.

მნიშვნელოვანია: პლატფორმა აწარმოებს მონაცემებს, არა პროგნოზებს. შედეგი გამოიყენება როგორც შემავალი მონაცემები შემდგომი დაავადების მოდელისთვის.

ვალიდაციის სცენარი

პროექტი ვალიდირებულია დენგეს ცხელების მაგალითზე ტაილანდში, თუმცა არქიტექტურა შექმნილია ისე, რომ იგივე ლოგიკა ვრცელდებოდეს სხვა ვექტორგადამტან დაავადებებზეც (მალარია, ქოლერა, ლაიმის დაავადება) და ნებისმიერ რეგიონზე, სადაც არსებობს საკმარისი მონაცემები.

2 სისტემის არქიტექტურა

პლატფორმა აგებულია სამი ფენისგან: frontend (Flutter), backend (Python/FastAPI) და გარე მონაცემთა წყაროები. Flutter არჩეულია იმიტომ, რომ ერთი კოდით შესაძლებელია აპლიკაციის აგება ვებ-ბრაუზერის, მობილურისთვის და დესკტოპისთვისაც – ეს მნიშვნელოვანია, რადგან პლატფორმა გამოიხატავს ფართო ხელმისაწვდომობისთვის ბმულის საშუალებით.




Figure 1: პლატფორმის მაღალი დონის არქიტექტურა

2.1 Backend-ის მოდულები

- config – გარემოს ცვლადები, მხარდაჭერილი რეგიონების/წყაროების რეესტრი;

- services/dengue – დაავადების შემთხვევების მონაცემები (OpenDengue, URL, ატვირთვა);
- services/climate – კლიმატური რეანალიზის მონაცემები (Open-Meteo, NASA POWER);
- services/etl – ორკესტრაცია: მოძიება, აგრეგირება, დაკავშირება;
- services/llm – Gemini API-სთან კომუნიკაცია, rate-limiting;
- services/cache – შედეგების დროებითი შენახვა და last_verified დროის ნიშნულის დამატება.

3 მონაცემთა ინტეგრაციის პროცესი (ETL)

ყოველი მოთხოვნა გადის შემდეგ ეტაპებს, რომლებიც მომხმარებელს ჩანს ეკრანზე – ეს იმისთვისაა, რომ მომხმარებელმა დარწმუნებით იცოდეს, რომ მისი ბრძანება სწორად შესრულდა.




Figure 2: ETL პროცესის ეტაპები (ერთი მოთხოვნისთვის)

3.1 გამჭვირვალობა და კეშირება

თითოეული ნაბიჯი ტექსტურად ფორმდება და უბრუნდება frontend-ს, ისე რომ მომხმარებელს შეუძლია ნახოს ზუსტად რა მოხდა. თუ იგივე მოთხოვნა მეორდება 15 წუთის განმავლობაში, სისტემა უბრუნებს კეშირებულ შედეგს (გარე API-ების ზედმეტი დატვირთვის თავიდან ასაცილებლად) და უჩვენებს ბოლო გადამოწმების დროის ნიშნულს (last_verified), რომ მომხმარებელმა იცოდეს რამდენად ახალია მონაცემი.

4 საკვანძო ცნებები კლიმატურ მონაცემებში

ეს თავი გამოსადეგია, როგორც მოკლე სასწავლო მასალა – განმარტავს ტერმინებს, რომლებსაც პლატფორმა იყენებს.

4.1 რეანალიზი (Reanalysis)

რეანალიზი არის წარსული ამინდის მონაცემების მეცნიერულად აღდგენილი, თანმიმდევრული სურათი. ის იქმნება ისტორიული დაკვირვებების (მეტეოსადგურები, თანამგზავრები, ხომალდები) და ფიზიკური ამინდის მოდელის შერწყმით. ეს არ არის ერთი კონკრეტული სადგურის ნედლი მონაცემი – ის წარმოადგენს საუკეთესო შეფასებას იმისა, თუ როგორი იყო ატმოსფერო კონკრეტულ ადგილას და დროს. პლატფორმა იყენებს ECMWF ERA5 რეანალიზს (Open-Meteo-ს საშუალებით) და NASA POWER-ს (MERRA-2 რეანალიზზე დაფუძნებული).

4.2 რეანალიზი vs. მოდელის პროგნოზი (Projection)

რეანალიზი აღწერს წარსულს და კორექტირდება რეალურ დაკვირვებებზე. მოდელის პროგნოზი (მაგ. CMIP6/CORDEX სცენარები) კი სიმულირებს მომავალ კლიმატს ემისიების სხვადასხვა დაშვებით და არ არის დაკავშირებული კონკრეტულ დაკვირვებულ მოვლენებთან. ამჟამინდელი იმპლემენტაცია იყენებს მხოლოდ ისტორიულ რეანალიზს (scenario=historical); მომავალი პროგნოზების ინტეგრაცია დაგეგმილია შემდეგ ეტაპზე.

4.3 Bias Correction (მიკერძოების კორექცია)

კლიმატის მოდელებს ხშირად აქვთ სისტემატური გადახრა რეალობისგან (მაგალითად, მუდმივად აჭარბებენ ნალექის რაოდენობას კონკრეტულ რეგიონში). Bias correction არის სტატისტიკური მეთოდი, რომელიც ასწორებს ამ გადახრას ისტორიულ დაკვირვებებთან შედარებით, სანამ მონაცემი გამოყენებული იქნება შემდგომი ანალიზისთვის. ეს განსაკუთრებით მნიშვნელოვანია მაშინ, როცა პროგნოზი (არა-რეანალიზის) მონაცემები გამოიყენება.

4.4 ემისიის სცენარები (Emission Scenarios)

ეს არის დაშვებები მომავალი სათბურის გაზების გამონაბოლქვის შესახებ (მაგ. SSP1-2.6 – დაბალი ემისია, SSP5-8.5 – მაღალი ემისია), რომლებზეც დაფუძნებულია კლიმატის მომავალი პროგნოზები. რადგან მომავალი ზუსტად უცნობია, მეცნიერები იყენებენ რამდენიმე სცენარს პარალელურად.

4.5 სივრცული და დროითი შეთანხმება (Join)

სხვადასხვა წყაროს მონაცემები განსხვავებული სივრცული (წერტილი, ბადე, რეგიონი) და დროითი (დღიური, თვიური, წლიური) გარჩევადობით მოდის. პლატფორმა კლიმატურ მონაცემებს დღიურიდან თვიურამდე აგრეგირებს (ტემპერატურა – საშუალო, ნალექი – ჯამი), რათა ის დაემთხვეს დაავადების შემთხვევების ჩვეულებრივ თვიურ ანგარიშგებას, შემდეგ კი აერთიანებს ორივეს საერთო თვე-წლის გასაღებით.

5 გამოყენებული მონაცემთა წყაროები

- OpenDengue – აკადემიური, საჯაროდ ხელმისაწვდომი დენგეს შემთხვევების არქივი (Clarke et al., 2024, Scientific Data). მოიცავს 39 ქვეყანას საკმარისი (12+ თვე) თვიური გარჩევადობით.
- Open-Meteo Historical Archive – ECMWF ERA5 რეანალიზზე დაფუძნებული, უფასო, გასაღების გარეშე ხელმისაწვდომი API.
- NASA POWER – ალტერნატიული სამეცნიერო კლიმატური წყარო (MERRA-2 რეანალიზი), ასევე გასაღების გარეშე ხელმისაწვდომი.
- მომხმარებლის საკუთარი წყარო – URL ან ატვირთული CSV ფაილი, თუ მომხმარებელს სურს საკუთარი სამეცნიერო მონაცემების გამოყენება.

6 ამჟამად განხორციელებული ფუნქციები

- ბუნებრივი ენის ინტერფეისის ნაცვლად – სტრუქტურირებული ფორმა (დაავადება, რეგიონი, ცვლადები, პერიოდი, წყარო), რომელიც შემდეგ ეტაპზე ჩანაცვლდება სრული LLM-ზე დაფუძნებული პარსინგით;
- 39 რეგიონი რეალური, თვიური სიხშირის დენგეს მონაცემებით;
- ორი ალტერნატიული სამეცნიერო კლიმატის წყარო;

- მომხმარებლის მიერ მითითებული URL ან ატვირთული ფაილი, როგორც დამატებითი მონაცემთა წყარო;
- ყოველი ნაბიჯის ტექსტური ჩვენება მომხმარებელს;
- შედეგის კეშირება last_verified დროის ნიშნულით;
- Gemini API-ს გამოძახებების სიხშირის შეზღუდვა (rate limiting);
- მიღებული მონაცემების გადმოწერა CSV/JSON ფორმატში;
- ერთი Docker კონტეინერი, რომელშიც Backend ემსახურება frontend-საც – მარტივი განთავსებისთვის.

7 შემდეგი ნაბიჯები

- სრული ბუნებრივი ენის მოთხოვნის დამუშავება LLM-ის მეშვეობით (ამჟამად: სტრუქტურირებული ფორმა);
- მომავალი კლიმატის პროგნოზების (CMIP6/CORDEX) და bias correction-ის ინტეგრაცია ემისიის სცენარების მხარდასაჭერად;
- გრიდირებული (რეგიონის მთელ ტერიტორიაზე გავრცობილი) მონაცემები ერთი წარმომადგენლობითი წერტილის ნაცვლად;
- ნამდვილი ფონური დამუშავების რიგი (job queue) გრძელვადიანი მოთხოვნებისთვის;
- დაავადების მოდელების პირდაპირი მიზმა გამომავალ მონაცემებზე.